TUGAS AKHIR - KI003498

APLIKASI ANAMNESIS BERDASARKAN GEJALA MENGGUNAKAN *FREQUENT PATTERN TREE GROWTH*

KEVIN ALIF FACHREZA
NRP 05111440000128

Dosen Pembimbing I
Dr. Eng. Chastine Fatichah, S.Kom., M.Kom

Dosen Pembimbing II
Anny Yuniarti, S.Kom, M.Comp.Sc

Departemen Informatika
Fakultas Teknologi Informasi dan Komunikasi
Institut Teknologi Sepuluh Nopember
Surabaya 2018

(Halaman ini sengaja dikosongkan)

TUGAS AKHIR – KI003498

APLIKASI ANAMNESIS BERDASARKAN GEJALA MENGGUNAKAN *FREQUENT PATTERN TREE GROWTH*

KEVIN ALIF FACHREZA
NRP 05111440000128

Dosen Pembimbing I
Dr. Eng. Chastine Fatichah, S.Kom., M.Kom

Dosen Pembimbing II
Anny Yuniarti, S.Kom, M.Comp.Sc

Departemen Informatika
Fakultas Teknologi Informasi dan Komunikasi
Institut Teknologi Sepuluh Nopember
Surabaya 2018

(Halaman ini sengaja dikosongkan)

UNDERGRADUATE THESES – KI003498

ANAMNESA APPLICATION BASED ON APPLICATION USING FREQUET PATTERN TREE GROWTH

KEVIN ALIF FACHREZA
NRP 05111440000128

First Advisor
Dr. Eng. Chastine Fatichah, S.Kom., M.Kom

Second Advisor
Anny Yuniarti, S.Kom, M.Comp.Sc

Department of Informatics
Faculty of Information and Communication Technology
Institut Teknologi Sepuluh Nopember
Surabaya 2018

(Halaman ini sengaja dikosongkan)

LEMBAR PENGESAHAN

APLIKASI ANAMNESIS BERDASARKAN GEJALA MENGGUNAKAN FREQUENT PATTERN TREE GROWTH

TUGAS AKHIR

Diajukan Untuk Memenuhi Salah Satu Syarat
Memperoleh Gelar Sarjana Komputer
pada
Bidang Studi Kecerdasan Komputasional
Program Studi S-1 Departemen Informatika
Fakultas Teknologi Informasi dan Komunikasi
Institut Teknologi Sepuluh Nopember

Oleh:
KEVIN ALIF FACHREZA
NRP : 05111440000128

Disetujui oleh Pembimbing Tugas Akhir:

1. Dr. Eng. Chastine Fatichah, S.Kom., M.Kom. .....
   (NIP. 197512202001122002) (Pembimbing 1)

2. Anny Yuniarti, S.Kom, M.Comp.Sc .....
   (NIP. 198106222005012002) (Pembimbing 2)

SURABAYA
JUNI, 2018

(Halaman ini sengaja dikosongkan)

APLIKASI ANAMNESIS BERDASARKAN GEJALA MENGGUNAKAN *FREQUENT PATTERN TREE GROWTH*

Nama Mahasiswa	**: Kevin Alif Fachreza**
NRP	**: 05111440000128**
Departemen	**: Informatika FTIK-ITS**
Dosen Pembimbing 1	**: Dr. Eng. Chastine Fatichah, S.Kom., M.Kom**
Dosen Pembimbing 2	**: Anny Yuniarti, S.Kom, M.Comp.Sc**

Abstrak

Machine learning merupakan salah satu bidang di teknologi informasi yang sedang naik daun. Teknologi ini dimanfaatkan diberbagai bidang kehidupan manusia, mulai dari perbankan, transportasi, sosial media, termasuk kesehatan. Potensi pemanfaatan *machine learning* pada bidang kesehatan sangatlah besar. Salah satunya adalah diagnosis penyakit. Diagnosis penyakit atau dikenal dengan tahap anamnesis pada kedokteran adalah suatu proses dimana dokter akan menanyakan kepada pasien gejala gejala yang dialami pasien. Sehingga dokter dapat memperkecil kemungkinan penyakit yang mungkin dialami pasien dan melakukan tes penunjang seperti lab atau radiologi untuk mendapatkan keputusan diagnosis final.

Banyak aplikasi yang dapat mendiagnosis penyakit, akan tetapi *user experience* yang buruk menyebabkan diagnosis meleset. Aplikasi tersebut biasanya akan meminta pengguna untuk memasukkan gejala mereka baik teks maupun berupa *checkboxes*. Padahal pasien tidak terlalu mengetahui gejala gejala spesifik atau yang berkorelasi yang dapat membantu dokter dalam mendiagnosis penyakit secara signifikan.

Aplikasi yang dibuat pada tugas akhir ini akan berfokus pada proses anamnesis, proses dimana pasien memberikan

informasi gejala yang dialami dengan spesifik dan sejelas mungkin. Sehingga dokter dapat memberikan diagnosis yang lebih baik. Untuk menyelesaikan masalah tersebut, akan digunakan algoritma *Frequent Pattern Tree Growth (FP Tree)*, yaitu salah satu metode *association rules* dimana algoritma ini dapat memetakan gejala gejala yang berkaitan, sehingga aplikasi dapat menanyakan gejala yang mungkin dialami oleh pasien berdasarkan gejala yang telah dimasukkan sebelumnya oleh pasien.

Dengan jumlah diagnosis penyakit sebanyak 66 penyakit, aplikasi ini memberikan hasil yang cukup baik. Dibuktikan dengan skenario pengujian dengan 198 data menghasilkan rata rata akurasi sebesar 69% dengan *classifier Naïve Bayes.* Dan rata rata akurasi sebesar 67% dengan *classifier Support Vector Machine*. Aplikasi juga diujikan kepada dokter spesialis dan mengatakan bahwa aplikasi memiliki kinerja baik pada proses anamnesis dan memberikan diagnosis yang sebagian besar sudah sesuai.

Kata kunci: ***Frequent Pattern Tree Growth*****, anamnesis, diagnosis,** ***Naïve Bayes, Support Vector Machine***

ANAMNESA BASED ON SYMPTOMS APPLICATION USING FREQUENT PATTERN TREE GROWTH

Student's Name	**: Kevin Alif Fachreza**
Student's ID	**: 05111440000128**
Departemen	**: Informatika FTIK-ITS**
First Advisor	**: Dr. Eng. Chastine Fatichah, S.Kom., M.Kom**
Second Advisor	**: Anny Yuniarti, S.Kom, M.Comp.Sc**

Abstract

Machine learning is currently one of the promising tech. This technology can be used in any fields, banking, transportation, social media, include health. Machine learning has a huge potency in health industry. One of them is diseases diagnosis. Diseases diagnosis or known as anamnesis in medical is a process where doctor will ask the patient about the symptoms or experience that patient felt. So doctor can narrow the possibility of diseases that the patient may suffer and do some lab and radiology tests to get final diagnosis decision

There is a lot app that able to diagnose diseases, but with bad user experience made the diagnosis went fumble. Those apps will asks user to input their symptoms using text or checkboxes. Whereas patients do not really know the specific symptoms or the symptoms that correlated to their main symptoms which can help doctor to diagnose disease significantly.

The app that made for this final project focused on anamnesis, where patients give information about their symptoms specifically and clearly. So doctor can give better diagnosis decision. To solve that problem, Frequent Pattern Tree Growth algorithm was used, Frequent Pattern Tree Growth is one of the association rules methods where this algorithm can map which

symptoms is related to other symptoms, so the app can ask the next symptoms based on the previous symptoms that inputted by user.

With 66 diagnoses, this app gave a pretty good result. Proven by scenarios of testing with 198 datas, yielding 69% average accuracy with classifier Naïve Bayes. And 67% average accuracy with classifier Support Vector Machine. This app also tested to a doctor specialist and said that the app gave good result in anamnesis and diagnoses that given by the app were mostly correlated based on anamnesis input.

Keywords : Frequent Pattern Tree Growth, anamnesis, diagnosis, Naïve Bayes, Support Vector Machine

KATA PENGANTAR

Alhamdulillahirabbil'alamin, segala puji dan syukur bagi Allah SWT, yang telah melimpahkan rahmat, dan hidayah-Nya sehingga penulis dapat menyelesaikan Tugas Akhir yang berjudul **"Aplikasi Anamnesis Berdasarkan Gejala Menggunakan Frequent Pattern Tree Growth"**

Pengerjaan Tugas Akhir ini merupakan suatu kesempatan yang berharga bagi penulis. Dengan pengerjaan Tugas Akhir, penulis dapat memperdalam, meningkatkan, serta menerapkan apa yang telah didapatkan penulis selama menempuh perkuliahan di Teknik Informatika ITS.

Terselesaikannya Tugas Akhir ini tidak lepas dari bantuan dan dukungan dari berbagai pihak. Dan dalam kesempatan ini penulis mengucapkan rasa syukur dan terima kasih kepada:

1. Allah SWT, karena atas izin-Nya lah penulis dapat menyelesaikan Tugas Akhir dengan baik.
2. Keluarga penulis (Mama, Papa, Yangti, Yangkong, Rehun, dan keluarga penulis yang lain) yang selalu memberikan dukungan moral dan material yang tidak ternilai.
3. Ibu Dr.Eng. Chastine Fatichah, S.Kom, M.Kom selaku pembimbing I Tugas Akhir yang telah memberikan banyak waktu untuk berdiskusi dan memberi semangat dan motivasi kepada penulis untuk menyelesaikan Tugas Akhir.
4. Ibu Anny Yuniarti, S.Kom, M.Comp.Sc selaku pembimbing II Tugas Akhir yang telah memberikan banyak yang telah memberikan bimbingan dan dukungan selama penulis menyelesaikan Tugas Akhir.
5. Dr Adi Suriyanto, Sp.OT selaku dokter yang meluangkan waktu dan pikiran dalam memberikan masukan dan melakukan pengujian pada Tugas Akhir ini.

6. Annisa Rahmawati, S.KG yang memberikan dukungan moral, motivasi, masukan dan hiburan pada pengerjaan Tugas Akhir ini.
7. Teman teman Jojoran yang menyediakan informasi dan tempat serta fasilitas dalam mengerjakan Tugas Akhir ini.
8. Yang terakhir untuk orang orang yang membaca dan akan mengembangkan Tugas Akhir ini. Semoga dapat mewujudkan aplikasi yang diimpikan.

Penulis memohon maaf apabila terdapat kekurangan dalam penulisan Tugas Akhir ini. Kritik dan saran penulis harapkan untuk perbaikan dan pembelajaran di kemudian hari. Semoga Tugas Akhir ini dapat memberikan Manfaat yang sebesar besarnya.

Surabaya, 30 Juni 2018

Kevin A Fachreza

DAFTAR ISI

DAFTAR GAMBAR

[Halaman ini sengaja dikosongkan]

DAFTAR TABEL

[Halaman ini sengaja dikosongkan]

DAFTAR KODE SUMBER

BAB I
PENDAHULUAN

Bab ini akan membahas latar belakang, rumusan masalah, batasan masalah, tujuan, manfaat, metodologi, dan sistematika laporan tugas akhir. Diharapkan dari penjelasan dalam bab ini gambaran tugas akhir secara umum dapat dipahami.

1.1 Latar Belakang

Kemajuan teknologi membuat informasi semakin mudah diakses. Masyarakat kini lebih haus informasi dibanding dengan generasi sebelumnya. Tidak terkecuali dalam bidang kesehatan. Masyarakat kini dapat membaca artikel kesehatan dengan mudah. Mendapatkan obat dengan mudah. Obat obatan kini bukan lagi sebuah rahasia dokter dan apoteker. Masyarakat kini cenderung mengetahui jenis jenis obat dan apa guna obat tersebut.

Sakit dapat terjadi pada siapapun. Mulai dari penyakit ringan hingga penyakit serius. Menurut statistik dari *UK Digital Health Report*, 1 dari 5 orang lebih memilih untuk melakukan diagnosis sendiri dengan bantuan *search engine* [1]. Hal ini tentu saja meningkatkan resiko kesalahan diagnosis pada pasien, dan dapat menyebabkan penyakit pasien semakin memburuk bahkan meninggal dunia.

Untuk mengatasi hal tersebut, diperlukan suatu solusi yang dapat memperkecil kesalahan masyarakat dalam mendiagnosis penyakit. Sehingga pasien lebih waspada dan tidak menganggap remeh gejala yang mereka alami. Solusi tersebut dapat dikemas dalam bentuk aplikasi yang didukung oleh kecerdasan buatan yang dapat mendiagnosis berdasarkan gejala gejala yang diberikan oleh pasien.

Dalam tugas akhir ini, akan digunakan *FP Tree* untuk dapat memberikan gejala gejala berkaitan dengan gejala utama pasien dan dapat memberikan diagnosis yang sesuai.

1.2 Rumusan Masalah

Rumusan masalah yang diangkat dalam tugas akhir ini dapat dipaparkan sebagai berikut :

1. Bagaimana cara menghasilkan pertanyaan gejala yang sesuai dengan jawaban pertanyaan gejala sebelumnya menggunakan *Frequent Pattern Tree Growth*?
2. Bagaimana menentukan diagnosis yang cocok berdasarkan gejala gejala pasien?
3. Bagaimana pengaruh *minimum support* terhadap performa *classifier*?

1.3 Batasan Masalah

Permasalahan yang dibahas dalam tugas akhir ini memiliki beberapa batasan antara lain:

1. Jumlah diagnosis sebanyak 66 diagnosis.
2. Implementasi dilakukan pada lingkungan kerja berbasis *web*.

1.4 Tujuan Pembuatan Tugas Akhir

Tujuan pembuatan tugas akhir ini adalah membangun aplikasi yang dapat membantu dokter dalam melakukan anamnesis dan memberikan diagnosis berdasarkan gejala gejala yang diberikan oleh pengguna menggunakan *Frequent Pattern Tree Growth*.

1.5 Manfaat Tugas Akhir

Tugas akhir ini akan berguna untuk memberikan perkiraan penyakit kepada masyarakat awam, serta memberikan masukan diagnosis kepada dokter. Input data gejala dan kondisi pasien dapat dibaca oleh dokter yang ditunjuk oleh pasien sebagai pemeriksa dirinya. Sehingga akan membantu proses pemeriksaan dokter terhadap pasien.

1.6 Metodologi

Metodologi yang akan digunakan pada tugas akhir ini adalah:

a. Penyusunan Proposal Tugas Akhir

Proposal akan berisi tentang pendahuluan, latar belakang, tujuan, manfaat, dan rumusan masalah. Yang akan didukung dengan penjelasan berupa tinjauan pustaka dan juga metode serta langkah langkah yang akan dilakukan untuk membangun produk.

b. Studi Literatur dan Wawancara

Sebelum pembuatan aplikasi, akan dilakukan studi literatur terkait aplikasi, dan juga melakukan wawancara kepada ahli, yang dalam tugas akhir ini adalah dokter untuk menyesuaikan metode yang dilakukan ahli untuk memberikan output yang diinginkan (diagnosis).

c. Analisis dan Desain

Pada tahap ini akan dilakukan analisis terkait bagaimana membangun model *Frequent Pattern Tree Growth* yang baik dan juga arsitektur terkait. Serta akan di analisa juga *dataset* yang sesuai untuk digunakan pada model.

d. Implementasi

Model yang telah dihasilkan pada langkah sebelumnya akan di implementasikan pada *server* yang berisi model, dan juga aplikasi untuk klien berupa *web*.

e. Evaluasi

Aplikasi yang telah dibuat akan dievaluasi oleh dokter dan juga pengguna untuk menilai kesesuaian anamnesis yang dilakukan oleh aplikasi dan kepuasan pengguna terhadap aplikasi. Selain itu aplikasi juga akan di evaluasi secara sistem menggunakan akurasi dan *retrieval*.

f. Penyusunan Buku Tugas Akhir

Pada tahap ini akan dilakukan penyusunan laporan berupa buku tugas akhir yang menjelaskan dasar teori

pada tugas akhir ini serta hasil implementasi pada tugas akhir.

1.7 Sistematika Penulisan Laporan Tugas Akhir

Buku tugas akhir ini bertujuan untuk mendapatkan gambaran dari pengerjaan tugas akhir ini. Selain itu, diharapkan dapat berguna untuk pembaca yang tertarik untuk melakukan pengembangan lebih lanjut. Secara garis besar, buku tugas akhir terdiri atas beberapa bagian seperti berikut ini.

1. Bab I. Pendahuluan
   Bab ini berisi penjelasan mengenai latar belakang masalah, tujuan, dan manfaat dari pembuatan Tugas Akhir. Selain itu rumusan permasalahan, batasan masalah, dan sistematika penulisan juga merupakan bagian dari bab ini.

2. Bab II Tinjauan Pustaka
   Bab ini berisi penjelasan tentang metode, algoritma, dan *library* yang digunakan pada pembuatan aplikasi ini. Pembahasan akan berfokus pada algoritma *associative rules* terutama pada *Frequent Pattern Tree Growth* dan juga metode klasifikasi yang digunakan yaitu *Naïve Bayes* dan *Support Vector Machine*.

3. Bab III Perancangan Perangkat Lunak
   Bab ini aka membahas mengenai perancangan, desain, model, dan proses proses lain yang digunakan untuk pembuatan aplikasi juga model *Frequent Pattern Tree Growth* serta model *Classifier*.

4. Bab IV. Implementasi
   Bab ini akan menjelaskan proses pembuatan aplikasi dengan bahasa *Python* yang dibantu oleh *library Flask* dan juga *PHP* dengan *framework laravel.* Juga akan membahas pembuatan

model menggunakan bahasa *Python* yang didukung dengan *ScikitLearn*.

5. Bab V. Hasil Uji Coba dan Evaluasi
   Bab ini akan menjelaskan hasil percobaan yang dilakukan secara sistem dengan *data testing* yang telah diambil dari sumber buku dan web, juga hasil percobaan yang dilakukan oleh dokter.

6. Bab VI. Kesimpulan dan Saran
   Bab ini akan membahas kesimpulan yang didapatkan dari hasil ujicoba dan juga akan membahas saran saran yang didapatkan baik dari penulis juga dari dokter yang melakukan uji coba. Sehingga aplikasi dapat dikembangkan menjadi lebih baik

[Halaman ini sengaja dikosongkan]

BAB II
DASAR TEORI

2.1Anamnesis

Pada sub bab ini akan dijelaskan pengertian anamnesis dan bagaimana proses anamnesis yang dilakukan oleh dokter.

2.1.1 Pengertian Anamnesis

Proses akumulasi data yang menyangkut data medis pasien, latar belakang pasien, termasuk keluarga, lingkungan, pengalaman, terutama ingatan untuk digunakan dalam menganalisa kondisi [2].

2.1.2 Langkah Langkah Anamnesis

Umumnya anamnesis dilakukan sesuai dengan cara cara berikut [3]:

1. Pasien memberikan gejala
   Pasien akan memberikan gejala yang dialami, misal : nyeri dada, badan panas.

2. Mendapatkan informasi lebih dalam mengenai gejala
   Dokter akan menanyakan lebih lanjut terkait gejala yang dialami pasien. Misal pada nyeri dada, dokter akan menanyakan pertanyaan berikut kepada pasien.
   - Dimana tepatnya letak nyeri pada dada?
   - Sejak kapan nyeri dada dirasakan?
   - Apakah nyeri dada sering sekali muncul, terkadang muncul, atau jarang muncul?
   - Apakah rasa nyeri berpindah?
   - Jika nyeri dada kambuh, berapa lama biasanya nyeri dada tersebut terasa?
   - Apakah nyerinya semakin sakit atau semakin tidak sakit?
   - Dalam skala 1-10, seberapa sakit yang anda rasakan?

3. Mencari gejala lain yang dialami pasien
   Dokter akan menanyakan apakah pasien mengalami gejala lain yang mungkin berkaitan dengan gejala sebelumnya. Misal : Nyeri dada, maka mungkin pasien akan mengalami sulit bernapas.

4. Menanyakan tindakan/obat yang sudah dilakukan terhadap gejala tersebut
   Dokter akan menanyakan tindakan atau obat apa yang telah dikonsumsi pasien. Lebih lanjut dokter akan menanyakan terkait dosis, nama obat, dan seberapa sering pasien mengonsumsi obat atau melakukan tindakan tersebut.

5. Menanyakan informasi kesehatan keluarga
   Dokter akan menanyakan informasi keluarga yang mungkin memiliki penyakit yang berkaitan yang bersifat genetik. Misal : diabetes

6. Menanyakan informasi lingkungan keseharian
   Dokter akan menanyakan bagaimana keseharian pasien, apakah pasien merokok, atau apakah pasien menggunakan obat obatan terlarang.

7. Menanyakan informasi lain terkait sistem tubuh lain yang tidak tercakup pada gejala
   Dokter akan menanyakan apakah ada sistem tubuh lain yang terganggu. Umumnya sistem yang akan ditanyakan dokter adalah sebagai berikut :

- Kardiovaskular
- Pernapasan
- Pencernaan
- Saraf
- Genital

- Muskuloskeletal
- Kejiwaan

8. Mengulas ulang keluhan yang diberikan pasien
   Dokter akan mengulas poin poin penting yang diberikan pasien sebelum memberikan diagnosis.

9. Dokter memberikan diagnosis

Pada sub bab ini akan dijelaskan apa pengertian *Frequent Pattern Tree Growth*, istilah istilah pada algoritma tersebut dan juga algoritmanya.

2.2 Frequent Pattern Tree Growth

Pada sub bab ini akan dijelaskan mengenai pengertian hingga algoritma tentang *Frequent Pattern Tree Growth*.

2.2.1 Pengertian *Frequent Pattern Tree Growth*

Frequent Pattern Tree Growth atau *FP Tree* merupakan salah satu algoritma *associative rules* yang sering digunakan pada berbagai permasalahan *data mining*. Algoritma ini sendiri bertujuan membuat *rules* yang didasarkan pada *tree* yang dibuat berdasarkan dataset yang diberikan.

Seperti *tree* pada umumnya, *tree* pada *FP Tree* juga memiliki *root*, *node* dan juga *leaf*. Pada *FP Tree* penempatan node akan didasarkan pada *support* pada setiap attribut pada sebuah data. Sehingga jika dilihat semakin tinggi posisi dari suatu *node* maka dapat dipastikan *node* tersebut memiliki *support* yang lebih tinggi daripada *child*-nya.

2.2.2 *Support*

Support adalah batas minimal indikasi seberapa sering *item* akan muncul pada *dataset*. [4]

$$support(A \rightarrow B) = P(A \cup B) \quad \textbf{(2.1)}$$

Keterangan :
A dan B adalah atribut

2.2.3 Algoritma *FP Tree*

Untuk mendapatkan rules dari *dataset*. *FP Tree* memiliki algoritma sebagai berikut:

Input : *Dataset*, dan *minimum support*
Output : *Rules*

Tahap 1. Pembuatan *Tree* [5]

1. *Scan database*, dan mengumpulkan kumpulan *frequent items*, dan *minimum support* untuk setiap *frequent items*. Urutkan data tersebut sesuai dengan nilai *support* secara *descending*.
2. Buat *root* dari *tree*
3. Pilih salah satu *frequent item* dan buat *node* untuk setiap *item*. Lanjutkan hingga *item* dari *set* tersebut habis.
4. Jika *node* telah terbuat untuk *item* tertentu, maka atribut jumlah akan ditambahkan sesuai dengan frekuensi dia muncul pada *node* tersebut.
5. Ulangi langkah 3 dan 4 hingga *tree* terbuat.

Tahap 2. Ekstrak *Frequent Pattern* [6]

1. Dari *tree* ambil salah satu *node* yang terletak paling akhir/bawah dari *tree*.
2. Lalu untuk ekstrak pertama maka akan mengambil *node* paling bawah.
3. Dari *node* terpilih akan di *traverse* dari *node* terpilih hingga *root* dan akan mendapatkan sebuah *path*.
4. *Path* yang dihasilkan akan dicatat. Jika *node* terpilih memiliki *support* > 1 maka akan ditulis sebanyak jumlah *support*.
5. Lakukan perhitungan *support* atribut pada *path* yang dihasilkan.
6. Setelah itu filter setiap atribut.

7. Dari atribut yang telah di filter akan dilakukan *divide and conquer*. Sehingga akan memiliki kombinasi *itemset* untuk atribut tersebut. *Support* dihitung berdasarkan banyaknya *itemset* yang muncul pada daftar *path* yang terbentuk.
8. Hilangkan *node* terpilih. Lalu naik ke *node* diatasnya.
9. Ulangi langkah 3.

Tahap 3. Ekstrak *Rules* [7]

1. Dari setiap *frequent pattern item* kita lakukan *divide and conquer* sehingga akan memunculkan banyak *itemset*. *Itemset* hasil *divide and conquer* disebut dengan anteseden, dan item yang tidak muncul pada *itemset* disebut konsekuen.
2. Lalu untuk setiap anteseden maka konsekuen akan digunakan rumus perhitungan *support*. S*upport* dari *itemset* akan dibagi dengan *support* dari anteseden.
3. Ulangi langkah pertama.

2.3 Naïve Bayes

Naïve Bayes adalah salah satu algoritma *supervised* pada data mining. Naïve Bayes adalah sebuah *classifier* berbasis probabilitas yang sederhana yang menghitung frekuensi dan kombinasi nilai pada *dataset* [8]. Algoritma *Naïve Bayes* berbasiskan pada *Bayes Theorem*. Dengan persamaan sebagai berikut [9] :

$$P(A|B) = \frac{P(B|A)\,P(A)}{P(B)} \quad \textbf{(2.2)}$$

Keterangan

A dan B adalah atribut
P(A) = Peluang A
P(B) = Peluang B
P (A | B) = Peluang A terhadap B
P (B | A) = Peluang B terhadap A

Naïve Bayes memiliki asumsi yang mendasar yaitu setiap fitur bersifat independen dan sama. Bersifat independen berarti setiap fitur tidak ada hubungannya oleh fitur lainnya. Misalnya hujan turun tidak ada hubungannya dengan angin yang bertiup kencang. Kedua fitur memiliki sifat sama artinya memiliki kontribusi atau *weight* yang sama. Asumsi yang dimiliki oleh Naïve Bayes pada umumnya tidak benar pada situasi dunia nyata [10].

2.3.1 Jenis *Naïve Bayes*

Naive Bayes memiliki jenis yang berbeda beda tergantung pada jenis data yang digunakan. Perbedaan jenis *Naïve Bayes* sangat berpengaruh terhadap performa yang dihasilkan *classifer*.

2.3.1.1 *Gaussian Naïve Bayes*

Gaussian Naïve Bayes digunakan saat attribut memiliki data yang bersifat kontinu, diasumsikan bahwa setiap nilai attribut memiliki hubungan dengan setiap kelas yang terdistribusi menurut *Gaussian Normal Distribution* [11].

2.3.1.2 *Multinomial Naïve Bayes*

Multinomial Naïve Bayes lebih cocok jika digunakan pada data yang secara terdistirbusi secara multinomial. Biasanya digunakan untuk klasifikasi teks untuk menghitung frekuensi kata yang muncul pada suatu dokumen [11].

2.3.1.3 *Bernoulli Naïve Bayes*

Bernoulli Naïve Bayes digunakan saat data memiliki nilai *binary.* Seperti *Multinomial*, *Bernoulli* cocok digunakan untuk klasifikasi teks yang digunakan untuk menandakan apakah kata tersebut ada pada dokumen atau tidak [10].

2.4 Support Vector Machine

Support Vector Machine atau *SVM* adalah sebuah *classifier* yang menggolongkan dengan cara membagi data menjadi area yang terpisah dengan *hyperplane* [12]. Dengan adanya *hyperplane* tersebut data data yang berbeda dapat dikategorikan menjadi 2 data berbeda.

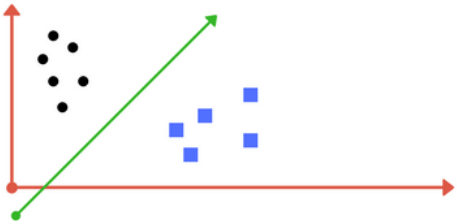

Gambar 2.1 Algoritma *SVM*

2.4.1 Hyperplane

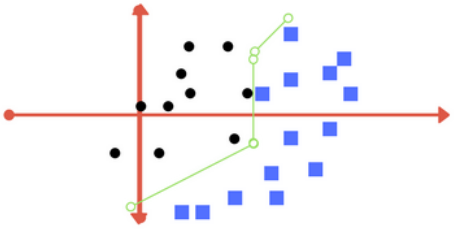

Gambar 2.2 Contoh *Hyperplane*

Hyperplane adalah pemisah bidang pada *SVM*. Umumnya *hyperplane* pada *SVM* adalah sebuah garis. Tetapi garis pemisah tidak selalu garis lurus. Garis pemisah dapat berupa persamaan kuadrat atau garis garis lainnya.

2.4.2 *Kernel SVM*

Pemilihan *kernel* penting dalam memecahkan masalah *SVM*. Perbedaan antar kernel dapat memberikan perbedaan performa yang cukup siginifikan. Pada *SVM* Linier permasalahan

dipecahkan menggunakan persamaan aljabar linier. Ada beberapa kernel *SVM* lain yang bisa digunakan, seperti kernel Polinomial, *RBF* dan *Gaussian*. *Kernel* Polinomial umumnya digunakan untuk pengolahan citra digital sedangkan *RBF* dan *Gaussian* bisa digunakan untuk data umum dan kita memiliki pengetahuan yang sedikit tentang data tersebut [13]. Performa *kernel* bergantung kepada data yang digunakan. Jika kita memiliki fitur data yang banyak sedangkan data sedikit, maka *kernel* linier lebih cocok digunakan [14].

2.4.3 SVM Multiclass

SVM memiliki performa yang baik saat memisahkan antar 2 data atau data yang memiliki 2 kelas saja. Tetapi *SVM* juga dapat digunakan untuk memecahkan masalah yang datanya memiliki banyak kelas. Ada 2 pendekatan yang digunakan yaitu *One vs All* dan *One vs One.*

2.4.3.1 *One vs All*

Pada pendekatan ini data akan di training satu per satu. Setiap kelas yang di training akan dilabeli sebagai kelas yang bernilai positif sedangkan kelas lain bernilai negatif. Walaupun secara komputasi pendekatan ini lebih cepat tetapi jika data tidak seimbang, dapat menyebabkan performa yang kurang baik [15].

2.4.3.2 *One vs One*

Pada pendekatan ini setiap kelas akan saling di training satu sama lain sehingga akan terbuat sebanyak N(N-1)/2 *classifier*. Pendekatan ini menghabiskan lebih banyak proses komputasi tetapi baik dalam menangani data yang tidak seimbang [15].

2.5 *Scikit Learn*

Scikit Learn adalah *library machine learning* gratis berbasiskan bahasa pemrograman *Python*. *Library* ini memiliki banyak fitur mulai dari klasifikasi, regresi, kluster termasuk *SVM, Random Forest, Gradient Boosting, KMeans, DBScan* dan

didesain untuk bekerja dengan *library* numerik dan ilmiah milik Python, *NumPy* dan *SciPy* [16].

2.6 *Python – Flask*

Flask adalah sebuah *microframework* untuk python [17]. *Flask* umumnya digunakan untuk membuat web. *Flask* tidak memiliki *database abstraction layer, form validation,* dan banyak fitur lainnya yang mana *library* lain sudah ada dan dapat mengatasi masalah tersebut. *Flask* mungkin *library* mikro namun mampu untuk digunakan dalam berbagai kebutuhan [18].

2.7 *PHP - Laravel*

Laravel adalah sebuah *framework* untuk *web* dengan *syntax* yang ekspresif dan elegan. *Laravel* mudah diakses, kuat, dan memiliki *tools* untuk aplikasi besar dan kuat. [19]. Berbeda dengan *flask*, *laravel* berbasiskan bahasa pemrograman PHP.

[Halaman ini sengaja dikosongka

BAB III
PERANCANGAN

3.1 Perancangan Data

Pada anamnesis, dokter melakukan pertanyaan kepada pasien mengenai gejala yang paling dirasakan. Lalu dokter akan menanyakan gejala berikutnya berdasarkan gejala tersebut. Dokter menanyakan gejala berikutnya berdasarkan kecenderungan antar gejala, bahwa jika seseorang memiliki gejala X maka orang tersebut juga cenderung untuk memiliki gejala Y, sehingga orang tesebut akan memiliki diagnosis Z. Sehingga berdasarkan hal tersebut dapat disimpulkan bahwa gejala memiliki hubungan dengan gejala lain jika gejala – gejala tersebut terdapat pada minimal satu diagnosis yang sama.

Dari analogi tersebut maka algoritma *Association Rules* cocok digunakan pada permasalahan ini. Dan algoritma *FP Tree* digunakan untuk memecahkan masalah tersebut. Untuk menjalankan *FP Tree* data yang akan digunakan pada aplikasi ini berasal dari berbagai sumber buku dan *website*. Penulis mengekstrak informasi data dari buku dan *website* dan memasukkannya pada *database*.

Data ini terdiri dari 858 data kasus, yang memiliki 66 diagnosis atau kelas. Serta 375 atribut. Data ini akan dibagi menjadi 2 kelompok yaitu data belajar dan data pengujian. Data belajar terdiri dari 10 kasus untuk setiap kelas. Dan data pengujian terdiri dari 3 kasus untuk setiap kelas.

Berikut adalah diagnosis yang terdapat pada dataset yang digunakan pada Tugas Akhir ini :

1. Rhinitis
2. Influenza
3. Faringitis
4. Tonsilitis
5. Laringitis
34. Apendisitis
35. Peritonitis
36. Askariasis
37. Ankilostomiasis
38. Skistosomiasis

6. Pneumonia
7. Bronkopneumonia
8. Pneumotoraks
9. PPOK
10. Epistaksis
11. Sinusitis
12. Tuberkulosis
13. Morbili
14. Varisela
15. Malaria
16. Leptospirosis
17. Filariasis
18. Lepra
19. Keracunan Makanan
20. Alergi Makanan
21. DBD
22. Anemia
23. HIV/AIDS
24. Lupus Eritematosus
25. Limfadenitis
26. Asam Lambung
27. Gastritis
28. Gastroenteritis
29. Disentri
30. Hemoroid
31. Hepatitis A
32. Hepatitis B
33. Kolesistitis
39. Taeniasis
40. Strongiloidiasis
41. Mata Kering
42. Buta Senja
43. Hordeolum
44. Konjungtivitis
45. Blefaritis
46. perdarahan subkonjungtiva
47. Astigmatisme
48. Hipermetropia
49. Miopia Ringan
50. Presbiopia
51. Katarak
52. Glaukoma
53. Trikiasis
54. Episkleritis
55. Hifema
56. Retinopati Diabetik
57. Otitis Eksterna
58. Otitis Media
59. Benda Asing di Telinga
60. Serumen Prop
61. Angina Pektoris Stabil
62. Infark Miokard
63. Takikardia
64. Gagal Jantung
65. Cardiorespiratory Arrest
66. Hipertensi

3.2 Desain Sistem Secara Umum

Tugas Akhir akan dibuat dalam beberapa tahap sesuai dengan

Gambar 3.1 Diagram Sistem Secara Umum. Tahap tahap tersebut adalah pembangunan dataset, pembuatan model FP Tree, tahap pembuatan model *classifier*, dan tahap pembuatan aplikasi untuk pengguna. Tahap pertama adalah pembangunan data, data data dari *database* akan diubah formatnya sehingga dapat dibaca dengan cepat oleh model *FP Tree* dan *classifier*. Pada tahap pembuatan model *FP Tree*, data akan difilter dengan *minimum support* sesuai dengan skenario. Lalu data yang telah di *filter* sesuai *minimum support* tersebut akan di training untuk membuat *rules*. *Rules* yang dihasilkan oleh *FP Tree* akan dimasukkan kedalam *database* yang nantinya akan digunakan oleh *server* untuk menentukan pertanyaan yang akan ditanyakan kepada pengguna.

Pada tahap pembuatan model *classifier*, dataset akan di filter berdasarkan *minimum support*, yang mana akan di *training* dengan *Naïve Bayes* dan juga *SVM*. Lalu masing masing hasil model akan di ujikan dengan data pengujian. Hasil dari pengujian ini adalah *classifer* dengan hasil yang terbaik, yang mana model ini yang akan digunakan untuk server *machine learning* yang akan menentukan diagnosis penyakit.

Tahap pembuatan aplikasi *user* akan menggabungkan antara hasil *rules* dengan model *classifier*. Aplikasi ini akan dibuat dengan *backend Laravel* dan *front-end Javascript Vanilla*.

3.2.1 Pembangunan Dataset

Data yang berasal dari buku (PPK Kedokteran, Diagnosis Banding Kedokteran, dan Kapita Selekta Kedokteran) dan wawancara dengan dokter akan dimasukkan ke dalam *database* yang memiliki tabel kasus, kasus_gejala, dan gejala. Dimana kasus akan menyimpan diagnosis, dan kasus_gejala akan menyimpan daftar gejala berdasarkan diagnosis pada kasus tersebut. Dari tabel tabel tersebut akan dibuat *dataset* yang terdapat pada 1 tabel yang sama agar bisa digunakan pada model.

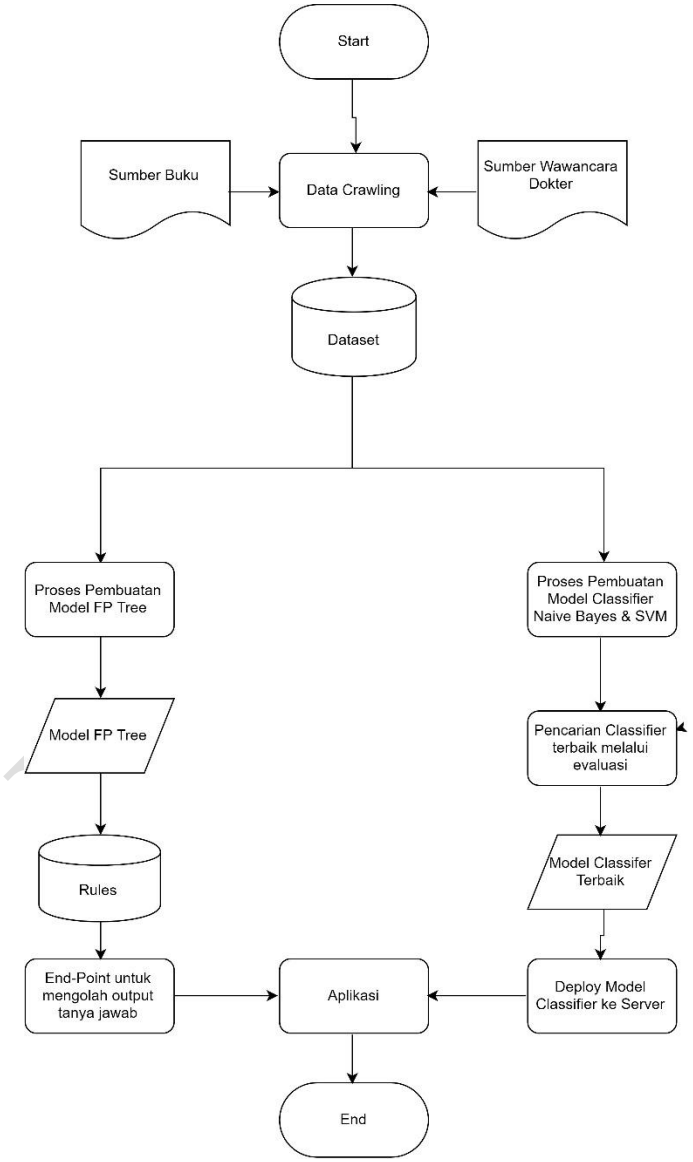

Gambar 3.1 Diagram Sistem Secara Umum

Sehingga akan dibuat tabel dengan kolom berisi id dari gejala, dan baris yang berisi id kasus. Sehingga akan terbentu suatu data dengan dimensi jumlah kasus X jumlah gejala. Dan untuk setiap baris atau kasus, jika kasus memiliki suatu gejala maka akan dicari id gejala tersebut pada kolom dan akan diberi angka 1 untuk indeks baris dan id gejala.

Tabel 3.1 Contoh Hasil Pembangunan Dataset

ID Kasus	289	290	291	292	293	294	295	296
5	1	1	0	0	0	1	1	0
6	0	0	0	0	1	1	1	0
7	0	0	0	0	0	0	0	1
8	0	0	1	1	1	1	1	1

3.2.2 Perancangan Model *FP Tree*

Dataset akan diolah dengan algoritma *FP Tree* sesuai dengan Gambar 3.2 Diagram Algoritma FP Tree. Algoritma akan diimplementasikan dengan bahasa pemrograman *Python*.

Pada tahap *filter* atribut pada masing masing data akan di *filter* berdasarkan *minimum support*. Adapun *minimum support* yang akan diskenariokan akan dijelaskan pada bab berikutnya.

Setelah di *filter*, data akan diurutkan berdasarkan urutan *support* dari yang terbesar hingga terkecil. Dan urutan tersebut akan menunjuk urutan sebelumnya yang lebih besar sehingga atribut yang memiliki *support* terbesar akan terletak pada *layer* teratas dan *support* terkecil akan terletak pada *layer* terbawah. Jika ada data yang memiliki atribut sama pada sebuah *layer* yang sama dengan *parent* yang sama maka *tree* tidak perlu membuat *node* baru, melainkan hanya menambahkan atribut frekuensi pada *node* yang sama tersebut.

Setelah tree terbentuk, maka akan dicari *Conditional Pattern* dari setiap *node*. Pencarian ini akan mencari *path* dari *node* tersebut hingga ke *root*. Dari proses ini akan memunculkan *paths* yang dilalui oleh *node* yang memiliki atribut yang sama.

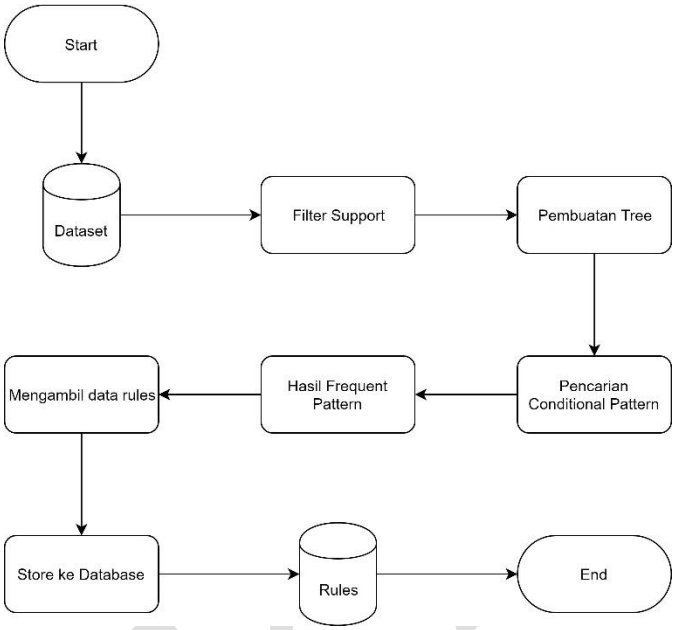

Gambar 3.2 Diagram Algoritma FP Tree

Dari *Conditional Pattern*, kita dapat mengekstrak *Frequent Pattern. Frequent Pattern* diambil dari kombinasi *Conditional Pattern* yang memiliki *support* lebih dari *minimum support*.

Dari hasil *Frequent Pattern*, akan diekstrak kombinasi yang akan memunculkan *rules*. *Rules* tersebut akan dihitung *confidence* dengan cara membagi hasil kombinasi dengan *pattern* utama. *Confidence* tidak akan di *filter* mengingat jumlah *rules* yang tidak begitu banyak.

Rules tersebut akan disimpan pada sebuah tabel pada *database* yang memiliki atribut *id, rules input, rules output* dan *probability*. Sehingga nantinya pada akhir proses akan memunculkan 9 tabel sesuai dengan jumlah skenario.

3.2.2.1 Contoh Proses Model *FP Tree*

Berdasarkan penjelasan pada Bab 3.2.2 Perancangan Model *FP Tree* akan dijelaskan contoh penggunaan algoritma hingga menghasilkan *rules*. Pada Tabel 3.2 diberikan sampel *dataset* dari *database*, dan pada Tabel 3.3 adalah hasil pengolahan data sampel yang akan diproses pada model *FP Tree*. Pada contoh kali ini digunakan *minimum support* sebanyak 2, karena terbatasnya jumlah sampel data.

Tabel 3.2 Sampel Dataset dari Database

Itemset
182, 163, 282, 281, 283
182, 283, 281, 282
279, 282, 281, 284
182, 279, 283, 282

Tabel 3.3 Hasil Pengolahan Sampel Data

163	**182**	**279**	**281**	**282**	**283**	**284**
1	1	0	1	1	1	0
0	1	0	1	1	1	0
0	0	1	1	1	0	1
0	1	1	0	1	1	0

Proses Pembangunan Model *FP Tree*

1. Filter *Support*

   Hitung *support* untuk setiap *itemset* dengan hasil Tabel 3.4. Lalu urutkan dan filter itemset berdasarkan support Tabel 3.5.

2. Pembuatan *Tree*

   Dari setiap *itemset* yang telah diurutkan akan dibuat *tree* yang memiliki atribut id gejala dan juga *support*, dengan hasil yang dapat dilihat pada Gambar 3.3.

Tabel 3.4 *Support* Atribut Data Sampel

Atribut	*Support*
163	1
182	3
279	2
281	3
282	4
283	3
284	1

Tabel 3.5 *Itemset* Yang Telah Diurutkan dan Filter

Itemset
282, 182, 281, 283
282, 182, 281, 283
282, 281, 279
282, 182, 283, 279

3. *Conditional Pattern*
   Dari *tree* pada Gambar 3.3 akan diambil *node node* yang terletak paling bawah dan akan di ekstrak *conditional pattern* dengan hasil pada Tabel 3.6.

4. *Frequent Pattern*
   Dari *conditional pattern* akan diekstrak *frequent pattern* menggunakan *divide and conquer* sehingga menghasilkan *frequent pattern*. Pada contoh kali ini akan diambil *conditional pattern* yang memilliki *prefix* 283 sehingga menghasilkan *frequent pattern* yang dapat dilihat pada Tabel 3.7.

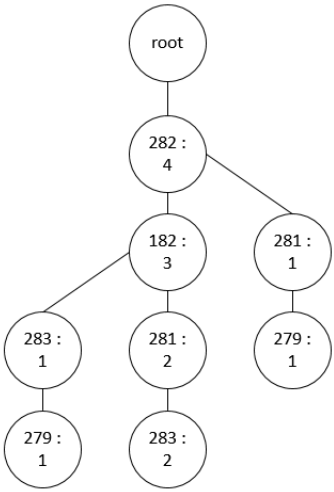

Gambar 3.3 Hasil *Tree* Data Sampel

Tabel 3.6 Hasil *Conditional Pattern*

Prefix	***Conditional Pattern Itemset***
279	282, 182, 283, 279
279	282, 281, 279
283	282, 182, 281, 283
283	282, 182, 281, 283
283	282, 182, 283
281	282, 182, 281
281	282, 182, 281
281	282, 281
182	282, 182
182	282, 182
182	282, 182
282	282
282	282
282	282
282	282

Tabel 3.7 Hasil *Frequent Pattern*

Prefix	*Pattern*	*Support*
283	283	3
	283, 281	2
	283, 182	3
	283, 282	3
	283, 182, 281	2
	283, 182, 282	3
	283, 281, 282	2
	283, 182, 281, 282	2
279	279	2
	279, 283	1
	279, 182	1
	279, 282	2
	279, 281	1
	279, 283, 182	1
	279, 283, 282	1
	279, 182, 282	1
	279, 281, 282	1
	279, 283, 182, 282	1
281	281	3
	281, 182	2
	281, 282	3
	281, 182, 282	2
182	182	3
	182, 282	3
282	282	4

5. *Rules*

Dari hasil *frequent pattern* pada Tabel 3.7, untuk masing masing *itemset* akan di ekstrak *rules*-nya. Setiap itemset akan diproses menggunakan *divide and conquer* yang dapat dilihat pada Tabel 3.8. Setelah mendapatkan hasil anteseden dan konsekuen maka akan dihitung

probabilitas sesuai dengan rumus pada sub bab 2.2.3 Algoritma *FP Tree*. Sehingga hasilnya dapat dilihat pada Tabel 3.9 hingga Tabel 3.12.

Tabel 3.8 Contoh Ekstraksi *Rules* Data Sampel

Itemset	Anteseden	Konsekuen
283, 182, 281	283	182, 281
	182	283, 281
	281	283, 182
	283, 182	281
	283, 281	182
	182, 281	283

Tabel 3.9 Hasil *Rules* Data Sampel

Prefix	Anteseden	Konsekuen	Probability
283	283	281	0.66
	281	283	0.66
	283	182	1
	182	283	1
	283	182	1
	182	283	1
	283	182,281	0.66
	182	283,281	0.66
	281	283,182	0.66
	283, 182	281	0.66
	283, 281	182	1
	182, 281	283	0.66
	283	182, 282	1
	182	283, 282	1
	282	283, 182	0.75
	283, 182	282	1
	283, 282	182	1
	182, 282	283	1
	283	281, 282	0.66
	281	283, 282	0.66

Tabel 3.10 Lanjutan Tabel 3.9

Prefix	Anteseden	Konsekuen	Probability
283	282	283, 281	0.5
	283, 281	282	1
	283, 282	281	0.66
	281, 282	283	0.66
	283	182, 281, 282	0.66
	182	283, 281, 282	0.66
	281	283, 182, 282	0.66
	282	283, 182, 281	0.5
	283, 182	281, 282	0.66
	283, 281	182, 282	1
	283, 282	182, 282	0.66
	182, 281	283, 282	1
	182, 282	283,281	0.66
	281, 282	283, 182	0.66
	283, 182, 281	282	1
	283, 182, 282	281	0.66
	283, 281, 282	182	1
	182, 281, 282	283	1
279	279	283	0.5
	283	279	0.33
	279	182	0.5
	182	279	0.33
	279	282	1
	282	279	0.5
	279	281	0.5
	281	279	0.33
	279	283, 182	0.5
	283	279, 182	0.33
	182	279, 283	0.33
	279, 283	182	1
	279, 182	283	1
	283, 182	279	0.33
	279	283, 282	0.5
	283	279, 282	0.33

Tabel 3.11 Lanjutan Tabel 3.10

Prefix	Anteseden	Konsekuen	Probability
279	282	279, 283	0.25
	279, 283	282	1
	283, 282	279	0.33
	279, 282	283	0.5
	279	182, 282	0.5
	182	279, 282	0.33
	282	279, 182	0.25
	279, 182	282	1
	279, 282	182	0.5
	282, 182	279	0.33
	279	281, 282	0.5
	281	279, 282	0.33
	282	279, 281	0.25
	279, 281	282	1
	279, 282	281	0.5
	281, 282	279	0.33
	279	283, 182, 282	0.5
	283	279, 182, 282	0.33
	182	279, 283, 282	0.33
	282	279, 182, 283	0.25
	279, 283	182, 282	1
	279, 182	283, 282	1
	279, 282	283, 182	0.5
	283, 182	279, 282	0.33
	283, 282	279, 182	0.33
	182, 282	279, 283	0.33
	279, 283, 182	282	1
	279, 182, 282	283	1
	283, 182, 282	279	0.33
	279, 283, 282	182	1
	281	182	0.66
	182	281	0.66
	281	282	1
	282	281	0.75
	281	182, 282	0.66

Tabel 3.12 Lanjutan Tabel 3.11

Prefix	Anteseden	Konsekuen	Probability
281	182	281, 282	0.66
	282	281, 182	0.5
	281, 182	282	0.66
	281, 282	182	0.66
	182, 282	281	0.66
182	182	282	1
	282	182	0.75

3.2.3 Perancangan Model *Classifier*

Pada sub bab ini akan dijelaskan bagaimana perancangan model *classifier* yaitu *Naïve Bayes dan* juga *SVM*.

3.2.3.1 *Naïve Bayes*

Naïve Bayes yang digunakan pada model adalah *Gaussian Naïve Bayes* karena *dataset* memiliki format *binary*. Model *Naïve Bayes* akan dibuat berdasarkan dataset yang telah di filter berdasarkan *minimum support* yang sama dengan skenario. Setelah itu dataset yang telah di filter tersebut akan di masukkan sebagai data belajar dari model *Naïve Bayes* yang akan dibuat. Model *Naïve Bayes* akan dibuat menggunakan *library*. Nantinya model ini akan diujikan dengan data testing yang telah ditetapkan sebelumnya.

Output dari model ini adalah 5 kemungkinan diagnosis yang memiliki *probability* tertinggi. Dengan format diagnosis dan persentase kemungkinan untuk setiap diagnosis.

3.2.3.2 *Support Vector Machine*

Pada tahap ini akan dibuat model *SVM* dengan *kernel linear*. Pada *Scikit Learn* lebih dikenal dengan *SVC*. Sama seperti *Naïve Bayes*, model *SVM* juga akan dibuat berdasarkan data belajar yang telah di filter berdasarkan *minimum support*. Model ini dibuat dengan library *Scikit Learn*.

Output dari model ini adalah 5 kemungkinan diagnosis yang memiliki *probability* tertinggi. Dengan format diagnosis dan persentase kemungkinan untuk setiap diagnosis.

3.2.4 Metode Evaluasi

Pada sub bab ini akan dijelaskan metode evaluasi dari tugas akhir ini. Evaluasi ini nantinya akan dibagi menjadi 2 yaitu berdasarkan akurasi dan juga *information retrieval*.

3.2.4.1 Evaluasi Berdasarkan Akurasi

Metrik akurasi akan didasarkan pada hasil klasifikasi dengan probabilitas klasifikasi tertinggi dari model *classifier* dengan hasil yang seharusnya. Dengan rumus sebagai berikut :

$$\boldsymbol{Akurasi} = \frac{\boldsymbol{TP+TN}}{\boldsymbol{TP+FP+FN+TN}} \qquad \textbf{(3.1)}$$

Keterangan :
FP = *False Positive*
FN = *False Negative*
TP = *True Positive*
TN = *True Negative*

3.2.4.2 Evaluasi Berdasarkan Information Retrieval

Metrik ini dihitung berdasarkan hasil pada data training yang akan dibandingkan dengan hasil model yang memiliki 5 hasil probabilitas tertinggi. Dan data benar tersebut akan dihitung berdasarkan peringkat, 100 untuk peringkat pertama dan turun 20 untuk setiap peringkat sehingga peringkat 5 akan mendapatkan nilai 20 dan jika data tidak muncul akan memberikan nilai 0. Atau disederhanakan menjadi rumus berikut :

$$\boldsymbol{Skor} = (\mathbf{5} - \{\boldsymbol{Peringkat}\}) * \mathbf{20} \qquad \textbf{(3.2)}$$

Keterangan :
Peringkat merupakan urutan diagnosis berdasarkan probabilitas

Selain itu juga akan dihitung nilai kemunculan dari hasil diagnosis. Sehingga jika ada salah satu hasil klasifikasi dari 5 hasil yang sesuai dengan hasil pada data training maka akan dinilai benar.

3.2.5 Perancangan Aplikasi

Pada sub-bab ini akan dijelaskan perancangan desain aplikasi. Perancangan aplikasi akan dibagi menjadi 3 yaitu :

a. Perancangan Desain Aplikasi Secara Umm
b. Perancangan Output Tanya Jawab
c. Perancangan Output Diagnosis

3.2.5.1 Perancangan Desain Aplikasi Secara Umum

Sesuai dengan Gambar 3.4 Diagram Alur Aplikasi, aplikasi akan dimulai dengan menanyakan identitas pasien, nama, usia dan juga jenis kelamin. Setelah itu pasien akan menginputkan salah satu gejala yang dirasa paling mengganggu pasien. Setelah itu aplikasi akan menanyakan pertanyaan gejala yang mungkin berikutnya berdasarkan jawaban dari pertanyaan gejala sebelumnya. Pertanyaan akan memiliki 2 jawaban ya atau tidak.

Aplikasi akan menghentikan pertanyaan dan akan memberikan jawaban jika aplikasi telah menanyakan 20 aplikasi atau *server* tidak memiliki pertanyaan lain untuk ditanyakan.

3.2.5.2 Perancangan *Output* Tanya Jawab

Agar aplikasi dapat menentukan pertanyaan mana yang harus ditanyakan selanjutnya, aplikasi akan mengakses *end-point* yang bertugas untuk menentukan pertanyaan selanjutnya. Adapun *end-point* ini akan menentukan pertanyaan selanjutnya berdasarkan jawaban pertanyaan sebelumnya. Untuk mendapatkan pertanyaan selanjutnya, *server* akan dirancangan sesuai dengan Gambar 3.5 Diagram Algoritma Tanya Jawab.

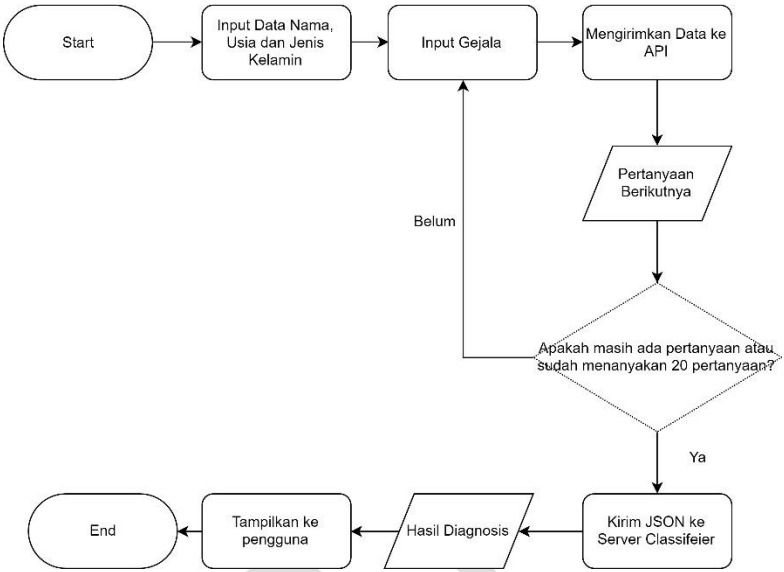

Gambar 3.4 Diagram Alur Aplikasi

Aplikasi tidak langsung mengekstrak *rules* berdasarkan gejala yang telah ditanyakan yang terdapat pada *database.* Melainkan gejala gejala sebelumnya akan diolah oleh *server* dengan cara mengambil data *rules* yang berasal dari output model *FP Tree*, dan akan menentukan kemungkinan pertanyaan selanjutnya berdasarkan input berupa gejala sebelumnya.

Adapun olahan khusus, seperti gejala yang memiliki sub gejala, seperti demam yang memiliki sub "demam tinggi" dan "demam lebih dari 3 hari", maka mesin akan langsung menanyakan sub gejala sub gejala tersebut jika telah mendapai salah satu sub gejala ditanyakan. Serta pengolahan data khusus yang didasari dari input identitas pasien yaitu usia dan jenis kelamin. Adapun berikut adalah pembagian kategori menurut usia :

a. Bayi 0 – 1
b. Balita dan Remaja 3 - 18

c. Dewasa 18 – 65
d. Tua > 65

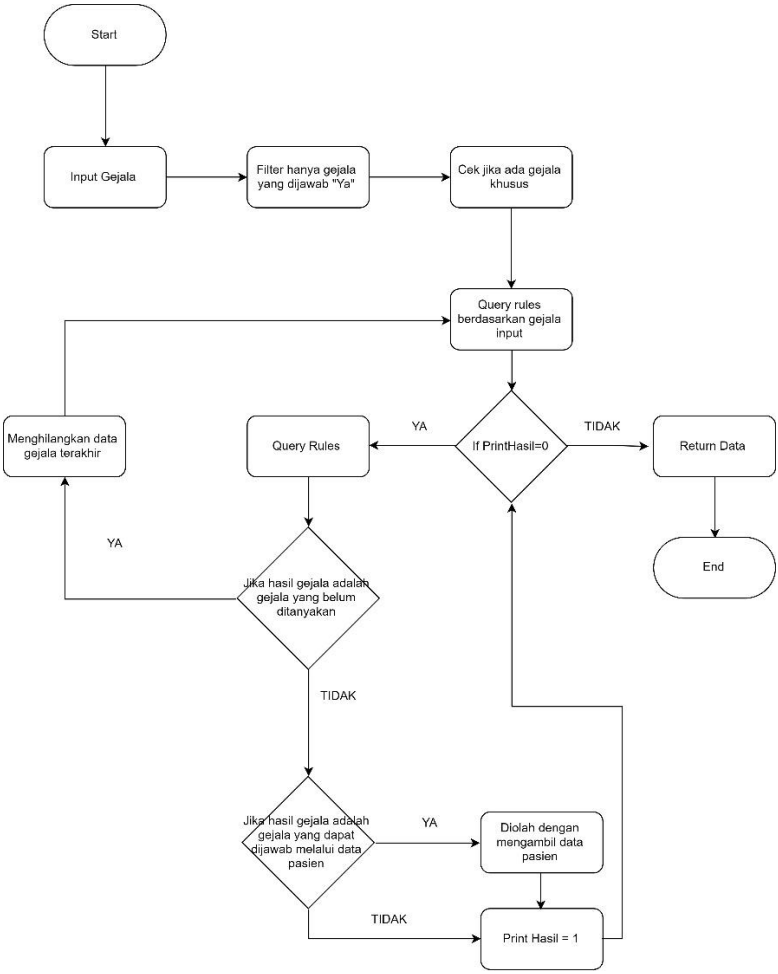

Gambar 3.5 Diagram Algoritma Tanya Jawab

3.2.5.3 Perancangan *Output* Diagnosis

Jika aplikasi sudah selesai menanyakan pertanyaan, maka aplikasi akan mengirimkan data gejala yang dialami pasien ke server *machine learning* yang dijalankan menggunakan *flask* dan akan mengolahnya pada model *machine learning*. Setelah itu *server* ini akan mengirimkan kembali hasil data ke aplikasi. Dan aplikasi akan menampilkan 5 kemungkinan diagnosis tertinggi beserta persentase.

[Halaman ini sengaja dikosongka

BAB IV
IMPLEMENTASI

Pada bab ini akan dijelaskan mengenai implementasi yang dilakukan berdasarkan rancangan yang telah dijelaskan pada bab sebelumnya. Implementasi kode program bahasa yang berbeda beda yang akan dijelaskan setiap potongan kode.

4.1 Lingkungan Implementasi

Spesifikasi komputer (*server*) yang digunakan untuk implementasi aplikasi ditampilkan pada Tabel 4.1

Tabel 4.1 Lingkungan Implementasi Perangkat Lunak

Komponen	**Spesifikasi**
CPU	*Intel® Core i5™ 7200U CPU @ 2.50 GHz (4 CPUs), ~ 2.7GHz*
GPU	*NVidia GeForce 720 930MX 2GB*
Sistem Operasi	*Windows 10 Pro*
Memori	8GB DDR4
Penyimpanan	1 TB
Perangkat Lunak Pendukung	• *Python* 3.6 • *Python* 2.7 • *PHP* 7.1 • *MySQL* 5.5

4.2 Implementasi

Sub-bab ini akan menjelaskan implementasi dari setiap tahap tahap yang telah dijelaskan pada bab sebelumnya.

4.2.1 Implementasi FP Tree

Pada sub bab ini akan dijelaskan tahap tahap pembuatan model *FP Tree* yang akan menghasilkan rules. Tahap pembuatan FP Tree ini sendiri ada 3 tahap yaitu :

1. *Filter Support*

2. Pembuatan *Tree*
3. Ekstrak *Frequent Pattern*
4. Ekstrak *Rules*

Pada tahap ini semua implementasi kode sumber menggunakan bahasa *Python*.

```
1.  def cleanData(data,min_support):
2.      items = data
3.      item_counter = Counter(x for sublist in data
    for x in sublist)
4.      temp_item_counter = Counter(item_counter)
5.
6.      for item in temp_item_counter:
7.          if(temp_item_counter[item] <
    min_support):
8.              del item_counter[item]
9.
10. itemOrder = {}
11. lengthItems = len(item_counter)
12.     for i in range(1,lengthItems+1):
13.         itemOrder[item_counter.most_common()[-
    i][0]] = i;
14.
15. count = 0;
16. for item in items:
17.     item = filter(lambda v: v in itemOrder, item)
18.     item.sort(key=lambda v: itemOrder[v],
    reverse=True)
19.     items[count] = item
20.     count+=1
21. data = [items,item_counter]
22.      return data
```

Kode Sumber 4.1 Filter pada *FP Tree*

4.2.1.1 *Filtering Support*

Pada tahap ini data akan diolah oleh suatu fungsi yang akan memfilter data sesuai dengan *minimum support* yang dimiliki data tersebut. Pada baris ke 5 – 7 atribut pada gejala akan di *filter* sesuai *minimum support*. Dan di baris ke 11 – 12 data akan diurutkan. Dan pada baris ke 15 – 19 data akan di filter sesuai dengan urutan dan atribut mana yang melebihi *minimum support*. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.1.

```
1.  def buildTree(dataset):
2.      root = Node("root",support = 0)
3.
4.      for data in dataset:
5.          parent = 0;
6.              for item in data:
7.                  if parent==0:
8.                      parent = root
9.                      child = find(parent,
    filter_=lambda node: node.name == item,
    stop=None, maxlevel = 2)
10.
11.             if child:
12.                 child.support = child.support + 1
13.                 parent = child
14.             else:
15.                 new_node = Node(item, parent=parent,
    support = 1)
16.                 parent = new_node
17. return root
```

Kode Sumber 4.2 Pembuatan *Tree* Pada *FP Tree*

4.2.1.2 Pembuatan *Tree*

Pada tahap ini akan data yang telah di filter akan dimasukkan ke sebuah *tree*. Output dari fungsi ini adalah sebuah *tree*, yang mana setiap *node* nya memiliki atribut nama, *child*, *parent*, dan

juga *support*. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.2.

4.2.1.3 Mengekstrak *Frequent Pattern*

Pada tahap ini dari *tree* fungsi akan mengekstrak *frequent pattern* yang digunakan untuk membuat *rules* pada tahap berikutnya. Pada awal fungsi yaitu baris 3 – 6 *tree* akan di *reverse* dari bawah. Selanjutnya *node node* pada *tree* akan di jelajahi satu per satu untuk mencari *frequent pattern* terbanyak.

```
1.    def mineFrequentPattern(dataset, tree,
      min_support,itemCounter):
2.       root = tree
3.       itemReverse = []
4.       lengthItems = len(itemCounter)
5.       for i in range(1,lengthItems+1):
6.
      itemReverse.append(itemCounter.most_common()[-
      i][0])
7.
8.       condPattern = {}
9.       frequentPattern = []
10.
11.      for item in itemReverse:
12.         nodes = findall_by_attr(root, item)
13.         condPatternParents = []
14.         for node in nodes:
15.            parent = str(node)
16.            parent = parent.replace("/root/","")
17.            parent = parent.split("'")[1]
18.            for i in range(0, node.support):
19.               condPatternParents.append(parent)
20.         condPattern[item] = condPatternParents
```

Kode Sumber 4.3 Ekstrak *Frequent Pattern*

```
21.     for item in itemReverse:
22.         itemsInPattern = []
23.             for pattern in condPattern[item]:
24.                 temp_pattern = pattern.split('/')
25.                 for temp_item in temp_pattern:
26.                     itemsInPattern.append(temp_item)
27.
28.             item_counter = Counter(itemsInPattern)
29.             temp_item_counter =
    Counter(item_counter)
30.
31.             for temp_item in temp_item_counter:
32.                 if(temp_item_counter[temp_item] <
    min_support):
33.                     del item_counter[temp_item]
34.
35.             willBeCombinatedItem = []
36.             willBeCombinatedItem = filter(lambda v:
    v in item_counter, itemReverse)
37.
38.             for L in range(1,
    len(willBeCombinatedItem)+1):
39.                 for resultcombo in
    combinations(willBeCombinatedItem, L):
40.                     resultcombo = list(resultcombo)
41.                     if item in resultcombo:
42.                         support = 0
43.                         for pattern in
    condPattern[item]:
44.                             pattern_array =
    pattern.split('/')
45.                             flag_support_increment = 1
46.                             for combo in resultcombo:
47.                                 if combo not in
    pattern_array:
```

Kode Sumber 4.4 Lanjutan Kode Sumber 4.3

```
48.                             flag_support_increment =
    0
49.                             if
    flag_support_increment == 1:
50.                                 support += 1
51.
52.     if support >= min_support:
53.
    frequentPattern.append(FrequentPattern(item,','.
    join(resultcombo) ,str(support)))
54.   return frequentPattern
```

Kode Sumber 4.5 Lanjutan Kode Sumber 4.4

4.2.1.4 Ekstrak *Rules*

Setelah berhasil mengekstrak *frequent pattern*, program selanjutnya akan mengekstrak *rules* dari data *frequent pattern* dan akan dimasukkan kedalam database. Implementasi ini dapat dilihat pada Kode Sumber 4.6.

4.2.2 Implementasi *Classifier*

Pada sub bab ini akan dijelaskan bagaimana tahapan pembuatan model *classifier*. Adapun pada tugas akhir ini *classifier* yang digunakan ada 2 yaitu :

1. *Naïve B*ayes
2. *Support Vector Machine*

Semua implementasi pada kode sumber pada tahap ini menggunakan bahasa *Python*.

4.2.2.1 *Naïve Bayes*

Berikut merupakan implementasi kode dari pembuatan model *Naïve Bayes*, yang mana *output*-nya adalah berupa *file* model yang dapat di buka lagi tanpa perlu *training* oleh *server machine learning*. Implementasi pada tahap ini dapat dilihat pada Kode Sumber 4.7.

```
1.  def generate_rules(filteredList,threshold):
2.      for i in range(len(filteredList)):
3.          subset = filteredList[i].pattern.split(',');
4.          for L in range(1, len(subset)):
5.              for resultsubset in combinations(subset, L):
6.                  left = list(resultsubset)
7.                  right = list(subset)
8.                  for item in left:
9.                  right.remove(item)
10.                 left_string = ','.join(left)
11.                 right_string = ','.join(right)
12.                 subset_string =  ','.join(subset)
13.                 support_subset = find_by_item(filteredList, subset_string)
14.                 support_left = find_by_item(filteredList, left_string)
15.                 support = float(float(support_subset)/float(support_left))
16.                 right = sorted(right, key=lambda x: int(x))
17.                 left = sorted(left, key=lambda x: int(x))
18.                 left_string = ','.join(left)
19.                 right_string = ','.join(right)
20.                 left_string = left_string.replace(" ","")
21.                 right_string = right_string.replace(" ","")
22.                 query = 'INSERT INTO rules_23(items,result,probability) VALUES("'+left_string+'","'+right_string+'","'+str(support)+'");'
23.                 cursor.execute(query)
24.                     cnx.commit()
```

Kode Sumber 4.6 Ekstrak Rules pada *FP Tree*

```
1. def generate_model():
2.     seed = 7
3.     numpy.random.seed(seed)
4.     dataframe =
       pandas.read_csv("../Users/Kevin/PycharmProjects
       /TugasAkhir/dataset/classifier-training-
       t5.csv", skipinitialspace=True)
5.     dataset = dataframe.values
6.     jumlah_gejala = len(dataset[0]) - 1
7.     X_train = dataset[:,0:jumlah_gejala]
8.     Y_train = dataset[:,jumlah_gejala]
9.     dataframe =
       pandas.read_csv("../Users/Kevin/PycharmProjects
       /TugasAkhir/dataset/classifier-testing-t5.csv",
       skipinitialspace=True)
10.    dataset = dataframe.values
11.    X_test = dataset[:,0:jumlah_gejala]
12.    Y_test = dataset[:,jumlah_gejala]
13.    label =
       pandas.read_csv("../Users/Kevin/PycharmProjects
       /TugasAkhir/dataset/label.csv")
14.    label = label.values
15.    model = BernoulliNB()
16.    y_pred = model.fit(X_train,
       Y_train).predict(X_test)
17.    class_map = model.classes_
18.    score = model.score(X_test, Y_test)
19.    filename =
       '../Users/Kevin/PycharmProjects/TugasAkhir/Naiv
       eBayes/model_architecture.sav'
20.    pickle.dump(model, open(filename, 'wb'))
```

Kode Sumber 4.7 Pembuatan Model *Naive Bayes*

4.2.2.2 *Support Vector Machine*

Berikut merupakan implementasi kode dari pembuatan model *Support Vector Machine*, yang mana *output*-nya adalah berupa *file* model yang dapat di buka lagi tanpa perlu *training* oleh

server machine learning. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.8.

```
1. def generate_model():
2.     seed = 7
3.     numpy.random.seed(seed)
4.     dataframe =
       pandas.read_csv("../Users/Kevin/PycharmProjects
       /TugasAkhir/dataset/classifier-training-
       t5.csv", skipinitialspace=True)
5.     dataset = dataframe.values
6.     jumlah_gejala = len(dataset[0]) - 1
7.     X_train = dataset[:,0:jumlah_gejala]
8.     Y_train = dataset[:,jumlah_gejala]
9.     dataframe =
       pandas.read_csv("../Users/Kevin/PycharmProjects
       /TugasAkhir/dataset/classifier-testing-t5.csv",
       skipinitialspace=True)
10.    dataset = dataframe.values
11.    X_test = dataset[:,0:jumlah_gejala]
12.    Y_test = dataset[:,jumlah_gejala]
13.    label =
       pandas.read_csv("../Users/Kevin/PycharmProjects
       /TugasAkhir/dataset/label.csv")
14.    label = label.values
15.    model = SVC(kernel = 'linear',
       probability=True).fit(X_train, Y_train)y_pred =
       model.fit(X_train, Y_train).predict(X_test)
16.    class_map = model.classes_
17.    score = model.score(X_test, Y_test)
18.    filename =
       '../Users/Kevin/PycharmProjects/TugasAkhir/Naiv
       eBayes/model_architecture.sav'
19.    pickle.dump(model, open(filename, 'wb'))
```

Kode Sumber 4.8 Pembuatan Model SVM

4.2.3 Implementasi Evaluasi

Pada tahap ini akan dijelaskan bagaimana *classifier* melakukan evaluasi dengan masing masing model. Bahasa yang digunakan untuk implementasi pada sumber kode semua dalam bahasa *Python*.

4.2.3.1 Implementasi Evaluasi Akurasi

Berikut adalah implementasi evaluasi akurasi, yang mana akan mengukur akurasi dari model berdasarkan input dan output data *testing*. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.9.

```
1. def getScore():
2.     filename =
   '../Users/Kevin/PycharmProjects/TugasAkhir/NaiveBa
   yes/model_architecture.sav'
3.     loaded_model = pickle.load(open(filename,
   'rb'))
4.     score = loaded_model.score(X_test, Y_test)
5.     return score
```

Kode Sumber 4.9 Evaluasi Akurasi

4.2.3.2 Implementasi Evaluasi *Retrieval*

Pada tahap ini ada 2 penilaian yang dilakukan. Yaitu penilaian berdasarkan kemunculan diagnosis benar dari 5 diagnosis yang di prediksi dan juga penilaian peringkat kemunculan diagnosis benar dari 5 diagnosis. Implementasi pada tahap ini dapat dilihat pada Kode Sumber 4.10.

4.2.4 Implementasi Aplikasi

Implementasi terakhir adalah implementasi pada aplikasi. Semua output dari tahap tahap sebelumnya akan disatukan sehingga dapat digunakan oleh user. Adapun pada tahap pembuatan aplikasi ini dibagi menjadi 3 bagian yaitu :

1. Tanya Jawab

2. Prediksi
3. *Interface*

```
1.  def getIRScore():
2.      predictions = model.predict_proba(X_test)
3.
4.      index = 0
5.      filewrite =
    '../Users/Kevin/PycharmProjects/TugasAkhir/lapor
    an/t18/svm_prediction_result.txt'
6.      with open(filewrite, 'w') as result_file:
7.          result_file.write('jumlah gejala ' +
    str(jumlah_gejala) + '\n')
8.          result_file.write('jumlah diagnosis ' +
    str(len(class_map)) + '\n')
9.          result_file.write('akurasi ' +
    str(score) + '\n\n')
10.
11.         item_pred_IR = 0;
12.         pred_class_score_array = []
13.         item_count = 0;
14.         for pred in predictions:
15.             top5 = pred.argsort()[-5:][::-1]
16.
17.             item_pred = top5[0]
18.             item_pred_str = class_map[item_pred]
19.
20.             item_true = Y_test[index]
21.
22.             string = str(item_pred_str) + ' ---
    ' + str(item_true)
23.             result_file.write(string+'\n')
24.
25.             pred_class_score = 100;
26.             pred_class_score_fix = 0;
```

Kode Sumber 4.10 Evaluasi *Information Retrieval*

```
27.             for item in top5:
28.                 result_file.write(str(class_map[item]) + ' '+ str(pred[item])+'\n')
29.                 temp_pred = str(class_map[item])
30.                 temp_true = str(item_true)
31.
32.                 if(pred_class_score_fix == 0):
33.                     if(temp_true == temp_pred):
34.                         pred_class_score_fix = pred_class_score
35.                         item_pred_IR += 1
36.                     else:
37.                         pred_class_score = pred_class_score - 20;
38.
39.                 pred_class_score_array.append(pred_class_score_fix)
40.             result_file.write('skor IR' + str(pred_class_score_fix) + '\n')
41.             result_file.write('\n')
```

Kode Sumber 4.11 Lanjutan Kode Sumber 4.10

4.2.4.1 Tanya Jawab

Pada bagian ini, *server* akan menerima *input* hasil dari pertanyaan terbaru dan pertanyaan sebelumnya. Lalu *server* akan melakukan pengolahan data. Dan mengambil *rules* dari *database* dan akan memberikan pertanyaan berikutnya berdasarkan probabilitas terbesar. Implementasi dari bagian ini menggunakan bahasa PHP. Algoritma lebih jelas dapat dilihat pada Gambar 3.5.

4.2.4.1.1 Filter Gejala

Dari input data gejala gejala yang telah dijawab pasien, server akan memfilter gejala yang dijawab ya oleh pasien. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.12.

4.2.4.1.2 Cek Gejala Khusus

Dilakukan cek untuk gejala 10 yaitu batuk dan 23 yaitu demam. Implementasi pada tahap ini dapat dilihat pada Kode Sumber 4.13.

```
1.     foreach($gejala as $key=>$value) {
2.           if($value == 1)
3.           array_push($arrayGejala, $key);
4.           array_push($arrayGejalaAsked, $key);
5.        }
```

Kode Sumber 4.12 Filter Gejala pada Tanya Jawab Aplikasi

```
1.     if(in_array(10, $arrayGejalaAsked) &&
       $gejala['10'] == 1)
2.        {
3.           if(!in_array(57, $arrayGejalaAsked) &&
       !in_array(66, $arrayGejalaAsked))
4.           {
5.              $id = 57;
6.           }
7.           elseif(in_array(57, $arrayGejalaAsked) &&
       $gejala['57'] == 0 && !in_array(66,
       $arrayGejalaAsked))
8.           {
9.           $id = 66;
10.          }
11.          elseif(in_array(66, $arrayGejalaAsked) &&
       $gejala['66'] == 0 && !in_array(57,
       $arrayGejalaAsked))
12.          {
13.             $id = 57;
14.          }
```

Kode Sumber 4.13 Cek Gejala Khusus pada Tanya Jawab Aplikasi

```
15.          if($id!=0){
16.          $rules = Gejala::where('id',$id)-
       >first();
17.             return json_encode([
18.                'command' => 'ask',
19.                'gejala' => $rules,
20.                'append' => 0,
21.                'append_value' => 0
22.             ]);
23.          }
24.       }
25.       if(in_array(23, $arrayGejalaAsked) &&
       $gejala['23'] == 1){
26.          $id = 0;
27.          if(!in_array(41, $arrayGejalaAsked))
28.          {
29.             $id = 41;
30.          }
31.          elseif(!in_array(177, $arrayGejalaAsked))
32.          {
33.             $id = 177;
34.             }
35.          if($id!=0)
36.          {
37.             $rules = Gejala::where('id',$id)-
       >first();
38.             return json_encode([
39.                'command' => 'ask',
40.                'gejala' => $rules,
41.                'append' => 0,
42.             'append_value' => 0
43.             ]);
44.          }
45.       }
```

Kode Sumber 4.14 Lanjutan Sumber Kode 4.13

4.2.4.1.3 Query Rules

Akan dilakukan *query* pada data *rules* berulang kali hingga mendapatkan pertanyaan yang akan ditanyakan kepada pasien, sesuai skema pada Gambar 3.5. Implementasi pada tahap ini dapat dilihat pada Kode Sumber 4.15.

```
1.      while(!$printResult)
2.         {
3.            $rules =
        Rules::where('items',$stringGejalaSorted)-
        >orderBy('probability','desc')->get();
4.      }
```

Kode Sumber 4.15 *Query Rules* pada Tanya Jawab Aplikai

4.2.4.1.4 Cek Jika Hasil *Query* Adalah Gejala Yang Belum Ditanyakan

Setelah mendapatkan hasil *query*. Maka hasil terebut akan di cek apakah hasil *query* pada tahap sebelumnya sudah ditanyakan. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.16.

4.2.4.1.5 Menghilangkan Gejala Terakhir

Setiap hasil *query*, jika belum mendapatkan hasil maka akan berulang kali melakukan tahap ini. Pada input gejala akan dihilangkan atribut gejala yang paling terakhir dimasukkan. Implementasi pada tahap ini dapat dilihat pada Kode Sumber 4.17.

4.2.4.1.6 Menjawab Melalui Data Pasien

Untuk setiap hasil query. Setiap atribut konsekuen akan di cek apakah dapat dijawab melalui data pasien. Jika ya dan membutuhkan informasi usia, maka server bisa langsung mengekstrak dari usia yang diinput. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.18.

```
1.     if(!in_array($rule->result, $arrayGejalaAsked))
2.                 {
3.                     if(in_array($rule->result,
       $arrayGejalaSpecial))
4.                     {
5.                         $gejala_result = explode(',',
       $rule->result);
6.                         $result = $this-
       >getSpecialRule($gejala_result[0],$pasien);
7.                         $command =
       $result['command'];
8.                         $gejala_data =
       $result['gejala'];
9.                         $append = $result['append'];
10.                        $append_value =
       $result['append_value'];
11.                        $printResult = 1;
12.                        $found = 1;
13.                        break;
14.                    }
15.                    else
16.                    {
17.                        $gejala_result = explode(',',
       $rule->result);
18.                        $gejala_data =
       Gejala::where('id',$gejala_result[0])->first();
19.                        $printResult = 1;
20.                        $command = 'ask';
21.                        $append = 0;
22.                        $found = 1;
23.                        break;
24.                    }
25.                }
```

Kode Sumber 4.16 Cek Hasil Query

```
1.     else
2.                 {
3.                     if(count($tempArrayGejala) > 1){
4.                         $out = 0;
5.                         array_pop($tempArrayGejala);
6.                         $arrayGejalaSorted =
       $tempArrayGejala;
7.                         sort($arrayGejalaSorted);
8.                         $stringGejalaSorted =
       implode(",", $arrayGejalaSorted);
9.                     }
10.                    elseif(count($tempArrayGejala)
       == 1){
11.                        $out=0;
12.                    }
13.                }
14.            }
```

Kode Sumber 4.17 Menghilangkan Gejala Terakhir pada Tanya Jawab Aplikai

```
1.     foreach($arrayGejalaSpecialUsia as $age){
2.           if(in_array($age, $arrayGejalaAsked))
3.           {
4.              array_push($arrayGejalaAsked, 35);
5.              array_push($arrayGejalaAsked, 48);
6.              array_push($arrayGejalaAsked, 331);
7.              array_push($arrayGejalaAsked, 139);
8.              break;
9.           }
10.       }
```

Kode Sumber 4.18 Menjawab Melalui Data Pasien pada Tanya Jawab Aplikai

4.2.4.2 Prediksi

Pada bagian ini, *server* akan membuka model hasil *training* yang memiliki performa terbaik. Lalu *server* akan menerima *json* dari *client* dan akan mengkonversi data menjadi array yang siap untuk di prediksi pada menggunakan model. Lalu hasil akan dikirimkan dengan format *json* ke *client*. Implementasi tahap ini dapat dilihat pada Kode Sumber 4.19.

```
1.  def predict():
2.      total_attributes=376
3.      label =
    pandas.read_csv("../Users/Kevin/PycharmProj
    ects/TugasAkhir/dataset/label.csv")
4.      label = label.values
5.     attributes =
    pandas.read_csv("../Users/Kevin/PycharmProj
    ects/TugasAkhir/dataset/attributes-t5.csv")
6.     attributes = attributes.values
7.     data = request.json
8.     data_gejala = data.get("gejala")
9.     number = str(5)
10.    gejala_array = []
11.    for i in attributes:
12.      number = str(i[0])
13.        if(data_gejala.get(str(number))):
14.          value_gejala =
    data_gejala.get(number)
15.        else:
16.          value_gejala = 0
17.    gejala_array.append(value_gejala)
18.    gejala_array_np_dummy = []
```

Kode Sumber 4.19 Implementasi Prediksi pada Server

```
19.   gejala_array_np_dummy.append(gejala_array)
20.     gejala_array_np =
      numpy.array(gejala_array_np_dummy)
21.
22.     seed = 7
23.     numpy.random.seed(seed
24.     dataframe =
      pandas.read_csv("../Users/Kevin/PycharmProj
      ects/TugasAkhir/dataset/classifier-
      training-t5.csv", skipinitialspace=True)
25.     dataset = dataframe.values
26.     jumlah_gejala = len(dataset[0]) - 1
27.     X_train = dataset[:,0:jumlah_gejala]
28.     Y_train = dataset[:,jumlah_gejala]

29.   #assigning testing
30.     dataframe =
      pandas.read_csv("../Users/Kevin/PycharmProj
      ects/TugasAkhir/dataset/classifier-testing-
      t5.csv", skipinitialspace=True)
31.     dataset = dataframe.values
32.       X_test = dataset[:,0:jumlah_gejala]
33.   Y_test = dataset[:,jumlah_gejala]

34.   #label
35.     label =
      pandas.read_csv("../Users/Kevin/PycharmProj
      ects/TugasAkhir/dataset/label.csv")
36.     label = label.values

37.   #Create a Gaussian Classifier
38.     model = BernoulliNB()
```

Kode Sumber 4.20 Lanjutan Kode Sumber 4.19

```
39.  # Train the model using the training sets
40.    y_pred = model.fit(X_train,
     Y_train).predict(X_test)
41.    class_map = model.classes_
42.    score = model.score(X_test, Y_test)
43.    predictions =
     model.predict_proba(gejala_array_np)
44.    result = []
45.    jsondata = '{ "result":['
46.    index = 0
47.    for pred in predictions:
48.      top5 = pred.argsort()[-5:][::-1]
49.        for item in top5:
50.          labels = label[item][0]
51.
     result.append(HasilDiagnosis(labels,pred[it
     em]))
52.          json_item_string = '{"diagnosis":"'
     + str(class_map[item])
     +'","probability":"'+ str(pred[item]) +'"}'
53.          if index < 4:
54.            json_item_string =
     json_item_string + ','
55.          index = index+1
56.          jsondata = jsondata +
     json_item_string
57.    jsondata = jsondata + "]}"
58.    format_jsondata = json.dumps(jsondata)
59.    return jsondata
```

Kode Sumber 4.21 Lanjutan Kode Sumber 4.20

4.2.4.3 *Interface*

Pada bagian interface akan dibagi menjadi 3 potongan kode. Bagian pertama adalah *HTML*, bagian kedua adalah *Javascript* untuk tanya jawab, dan bagian yang ketiga adalah *javascript* untuk diagnosis penyakit. Implementasi pada bagian pertama dapat dilihat pada Kode Sumber 4.22. Implementasi pada bagian kedua dapat dilihat pada Kode Sumber 4.26. Dan Implementasi pada bagian ketiga dapat dilihat pada Kode Sumber 4.29.

```
1.    @section('content')
2.    <div class="container">
3.       <div class="row">
4.          <div class="col-xs-12 col-md-8 col-md-
      offset-2">
5.             <div class="card">
6.                <div class="card-content"
      style="padding-top: 50px; padding-bottom:
      50px">
7.                   <div id="welcome" class="text-
      center">
8.                      <h4>Selamat datang di Aqeela
      dari Medify</h4>
9.                      <p>Aqeela akan membantu anda
      untuk mendiagnosis penyakit anda berdasarkan
      gejala yang anda alami. </p>
10.                     <button class="btn btn-
      primary">Selanjutnya<div class="ripple-
      container"></div></button>
11.                  </div>
12.                  <div id="pasien" class="text-
      center" style="display: none">
13.                     <h4>Isi data berikut</h4>
14.                     <div class="row">
15.                        <div class="col-md-8 col-
      md-offset-2 col-xs-12">
```

Kode Sumber 4.22 Implementasi HTML pada Aplikasi Pengguna

```
16.                         <input class="form-
    control" type="text" id="pasien-nama"
    placeholder="Nama">
17.
18.   <input class="form-control" type="text"
    id="pasien-usia" placeholder="Usia">
19.                         <select
    class="selectpicker" data-style="btn btn-primary
    btn-round" title="Single Select" data-width="100%"
    id="pasien-gender">
20.                             <option value="1"
    selected>Laki laki</option>
21.                             <option
    value="2">Perempuan</option>
22.                         </select>
23.                     </div></div>
24.                 <button class="btn btn-
    primary">Selanjutnya<div class="ripple-
    container"></div></button>
25.             </div>
26.             <div id="gejala-first" class="text-
    center"  style="display: none">
27.                 <h4>Apa gejala yang paling anda
    rasakan?</h4>
28.                 <div class="row">
29.                     <div class="col-md-8 col-md-
    offset-2 col-xs-12">
30.                         <select
    class="selectpicker" data-style="btn btn-primary
    btn-round" title="Single Select" data-live-
    search="true" data-size="7">
31.                             @foreach($gejalas as
    $gejala)
32.                                 <option
    value="{{$gejala->id}}">{{$gejala->name}}</option>
33.                             @endforeach
34.                     </select>
```

Kode Sumber 4.23 Lanjutan Kode Sumber 4.22

```
35. </div>
36.                 </div>
37.                 <button class="btn btn-
    primary">Selanjutnya<div class="ripple-
    container"></div></button>
38.             </div>
39.             <div id="gejala-question"
    class="text-center"  style="display: none;min-
    height: 300px">
40.                 <h4>Apakah anda merasakan <span
    id="fill-gejala"></span></h4>
41.                 <button class="btn btn-primary
    yes">Ya<div class="ripple-
    container"></div></button>
42.                 <button class="btn btn-danger
    no">Tidak<div class="ripple-
    container"></div></button>
43.             </div>
44.             <div id="diagnosis-warning"
    class="text-center"  style="display: none;">
45.                 <h4>Setelah ini, saya akan
    memberikan kamu 5 diagnosis penyakit yang
    mungkin kamu alami</h4>
46.                 <p>Ingat diagnosis ini tidak
    bersifat final, kami rekomendasikan anda
    menemui dokter untuk mendapatkan kepastian
    mengenai penyakit yang anda derita.</p>
47.                 <button class="btn btn-
    primary">Selanjutnya<div class="ripple-
    container"></div></button>
48.             </div>
49.             <div id="diagnosis-result"
    class="row" style="display: none">
50.                 <h4 class="text-center
    ">Penyakit yang mungkin kamu derita</h4>
51.                 <div id="result" class="col-md-4
    col-md-offset-4">
```

Kode Sumber 4.24 Lanjutan Kode Sumber 4.23

```
52.                 </div>
53.             </div>
54.         </div>
55.     </div>
56.   </div>
57. </div>
58. </div>
59. @endsection
```

Kode Sumber 4.25 Lanjutan Kode Sumber 4.24

```
1  function setGejala(index,value){
2    if(value == 1)
3    {
4        count_true++
5    }
6    count++
7    gejalaPasien.set(index,value)
8    var pasienNama = $('#pasien-nama').val()
9    var pasienUsia = $('#pasien-usia').val()
10   var pasienGender = $('#pasien-gender').val()
11
12   var gejalaPasienJSON = new Backbone.Model({
13       "gejala" : gejalaPasien,
14       "jenis_kelamin" : pasienGender,
15       "usia" : pasienUsia
16   });
17
18   var gejalaPasienJSON =
     JSON.stringify(gejalaPasienJSON);
19
```

Kode Sumber 4.26 Javascript Tanya Jawab Pada Interface User

```
20  $.ajax({
21      type: "POST",
22      url: "{{url('api/app/question/next')}}",
23      contentType: "application/json",
24      headers: {
25          'Access-Control-Allow-Credentials' : 'true'
26      },
27      data : gejalaPasienJSON,
28      processData: false,
29      success: function (data) {
30          var obj = JSON.parse(data)
31          var command = obj.command
32          var gejala = obj.gejala
33          var append = obj.append
34          var append_value = obj.append_value
35          currentGejala = gejala.id
36          console.log(count)
37          if(count_true > 10)
38          {
39              submitFinal(gejalaPasienJSON);
40          }
41          else if(count > 20)
42          {
43              submitFinal(gejalaPasienJSON);
44          }
45          else
46          {
47              if(command === 'ask')
```

Kode Sumber 4.27 Lanjutan Kode Sumber 4.26

```
48                {
49                    console.log('ask')
50                    $("#gejala-
    question").fadeOut(500, function(){
51                        $("#gejala-
    question").fadeIn(500);
52                        $('#gejala-question
    #fill-gejala').html(gejala.name' - '+
    gejala.id);
53                    });
54                }
55                else if(command === 'append')
56                {
57                    console.log('append')
58
     setGejala(append,append_value);
59                }
60                else
61                {
62                    console.log(command)
63
     submitFinal(gejalaPasienJSON);
64                }
65            }
66        },
67        error: function (e) {
68            alert(e)
69        }
70    });
71 }
```

Kode Sumber 4.28 Lanjutan Kode Sumber 2.27

```
function submitFinal(gejalaPasienJSON)
{
  $.ajax({
      type: "POST",
      url: "http://127.0.0.1:5000/predict",
      contentType: "application/json",
      headers: {
          'Access-Control-Allow-Credentials' : 'true'
      },
      data : gejalaPasienJSON,
      dataType : 'json',
      processData: false,
      success: function (response) {
          diagnosis = response.result;
          $( "#diagnosis-result #result" ).html('')

          $.each(diagnosis, function(item) {
              probability = Number(diagnosis[item].probability * 100).toFixed(2);
              result = '<h4 class="title">'+diagnosis[item].diagnosis+'<small>· '+probability+'%</small></h4>'

              $( "#diagnosis-result #result" ).append( result );
          })

          $("#gejala-question").fadeOut(500, function(){
```

Kode Sumber 4.29 Implementasi *Javascript* Prediksi Diagnosis pada *user*

```
25                  $("#diagnosis-
    warning").fadeIn(500);
26              });
27          },
28          error: function (e) {
29              alert(e);
30          }
31      });
32
```

Kode Sumber 4.30 Lanjutan Kode Sumber 4.29

BAB V
PENGUJIAN DAN EVALUASI

Pada bab ini akan dijelaskan skenario dan hasil dari uji coba aplikasi yang telah diimplementasikan.

5.1 Lingkungan Pengujian

Lingkungan pengujian yang digunakan untuk *server* dengan spesifikasi pada Tabel 5.1 Lingkungan Pengujian *Server* dan *client* (pengguna) dengan spesifikasi pada Tabel 5.2 Lingkungan Pengujian *Client* (Pengguna).

Tabel 5.1 Lingkungan Pengujian *Server*

Komponen	**Spesifikasi**
CPU	*Intel® Core i5™ 7200U CPU @ 2.50 GHz (4 CPUs), ~ 2.7GHz*
GPU	*NVidia GeForce 720 930MX 2GB*
Sistem Operasi	*Windows 10 Pro*
Memori	8GB DDR4
Penyimpanan	1 TB
Perangkat Lunak Pendukung	• *Python* 3.6 • *Python* 2.7 • *PHP* 7.1 • *MySQL* 5.5 • *Google Chrome*

5.2 Data Uji Coba

Data yang digunakan untuk uji coba aplikasi ini adalah kumpulan data kasus yang berasal dari dataset dan berjumlah 199 data. Sedangkan data training yang digunakan pada uji coba ini adalah 660 data kasus yang berasal dari dataset. Adapun data rules yang digunakan pada skenario data uji coba ini dijelaskan pada Tabel 5.3.

Tabel 5.2 Lingkungan Pengujian *Client* (Pengguna)

Komponen	**Spesifikasi**
CPU	*Intel® Core i5™ 7200U CPU @ 2.50 GHz (4 CPUs), ~ 2.7GHz*
GPU	*NVidia GeForce 720 930MX 2GB*
Sistem Operasi	*Windows 10 Pro*
Memori	8GB DDR4
Penyimpanan	1 TB
Perangkat Lunak Pendukung	• *Python* 3.6 • *Python* 2.7 • *PHP* 7.1 • *MySQL* 5.5 • *Google Chrome*

Tabel 5.3 Jumlah Data Gejala dan Rules

Minimum Support	**Jumlah Gejala**	**Rules**
3	250	289,940
5	204	30,940
8	159	6,006
10	133	3,290
12	110	1,932
15	88	1,070
18	74	706
20	64	528
23	57	346

5.3 Skenario Uji Coba

Skenario pertama yang dijalankan pada evaluasi ini berupa perhitungan akurasi dan *retrieval*. Pengujian ini bertujuan untuk mencari *model classifer* terbaik yang akan digunakan pada *server classifier*. Pengujian akan dimulai dengan filter *support* untuk gejala gejala. Ada 9 *minimum support* yang akan di filter (3, 5, 8, 10, 12, 15, 18, 20, 23). Setelah filter, data testing gejala ini akan di ujikan kepada model *classifer*. Dan hasilnya akan dicatat pada file teks.

Skenario kedua adalah menguji coba aplikasi kepada pengguna. Dengan batasan pertanyaan hingga 30, pengguna akan menggunakan aplikasi hingga pengguna merasa jenuh. Jika pengguna telah merasa jenuh, pengguna dapat memberitahu dan diizinkan untuk berhenti melakukan pengujian aplikasi. Tujuan dari skenario ini adalah mencari jumlah pertanyaan yang tidak menyebabkan pengguna bosan hingga berakibat keluar dari aplikasi sebelum muncul diagnosis dari aplikasi.

Pada skenario kedua ini uji pengguna dilakukan oleh masyarakat awan yang berusia 20 – 25 tahun. Masing masing mencoba aplikasi 1 kali, setiap pengguna diberikan 1 diagnosis penyakit yang populer pada skenario ini yang digunakan adalah demam berdarah, dan ankilostomiasis (cacing tambang). Jika pengguna tidak mengetahui banyak mengenai diagnosis tersebut maka akan diberikan sedikit gambaran dan daftar gejala yang mungkin. Dan setelah diberikan penjelasan dan daftar gejala pengguna bebas untuk mengisi berdasarkan apa yang dibaca atau pengalaman yang dia miliki.

Selain itu aplikasi juga akan diujikan kepada dokter untuk menilai bagaimana pendapat dokter mengenai akurasi dari pemetaan gejala dan juga hasil diagnosis dokter. Pada uji coba ini dokter akan memasukkan gejala awal dan menjawab pertanyaan, lalu dokter akan menyimpulakan apakah diagnosis yang diberikan masuk akal dengan hasil yang diberikan oleh aplikasi. Pada pengujian ini dokter akan melakukan pengujian aplikasi sebanyak 10 kali.

5.4 Hasil Uji Coba

Pada sub bab ini akan dijelaskan bagaimana hasil dari hasil uji coba dari evaluasi secara sistem dan juga evaluasi oleh dokter. Adapun Gambar 5.1, Gambar 5.2, dan Gambar 5.3 adalah contoh tampilan dari aplikasi yang akan digunakan untuk pengujian.

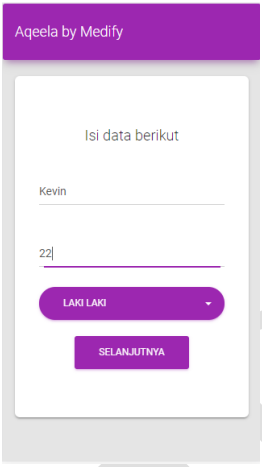

Gambar 5.1 Tampilan Hasil Diagnosis

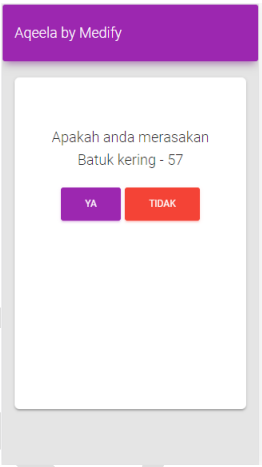

Gambar 5.2 Pengisian Data Pasien

Gambar 5.3 Tampilan Tanya Jawab

5.4.1 Hasil Uji Sistem

Hasil uji skenario sistem akan dibagi menjadi 2 jenis evaluasi. Evaluasi secara akurasi dan evaluasi secara *information retrieval*. Pada uji coba berdasarkan akurasi ini dibagi menjadi 2 *classifer* yaitu *Naïve Bayes* dan *SVM*.

Pada Gambar 5.4 dan

Tabel 5.4, dapat dilihat bahwa cenderung menurun walaupun dengan selisih yang sangat kecil. Pada saat *minimum support* bernilai 5, *Naïve Bayes* memiliki akurasi tertinggi

sedangkan SVM memiliki akurasi tertinggi pada saat *minimum support* bernilai 3.

Tabel 5.4 Hasil Uji Akurasi

Min Support	***Naïve Bayes***	***SVM***
3	75.897	75.897
5	76.381	75.376
8	74.371	73.366
10	74.874	71.859
12	71.859	71.356
15	71.859	69.849
18	63.316	60.301
20	60.301	57.788
23	56.281	51.256
Rata rata	69.45	67.44

Selisih pada setiap hasil akurasi juga berbanding tipis antar *minimum support*. Rata rata selisih hasil akurasi classifier pada setiap *minimum support* adalah 2,69 untuk *Naïve Bayes* dan 3,08 untuk *SVM*. Selisih terbesar antar support terjadi saat *minimum support* 15 dibandingkan dengan *minimum support* 18, selisih antar kedua hasil ini adalah 8,5% untuk *Naïve Bayes* dan 9,5% untuk *SVM*. Adapun rata rata selisih hasil akurasi antar *minimum support* pada saat *minimum support* diantara 3 – 15 adalah 1.2% untuk *Naïve Bayes* dan *SVM*. Selisih dari hasil tertinggi dengan terendah adalah 20,1% untuk *Naïve bayes* dan 24,6% untuk *SVM*. Rata rata dari *Naïve Bayes* adalah 69,45% dan *SVM* adalah 67,44%.

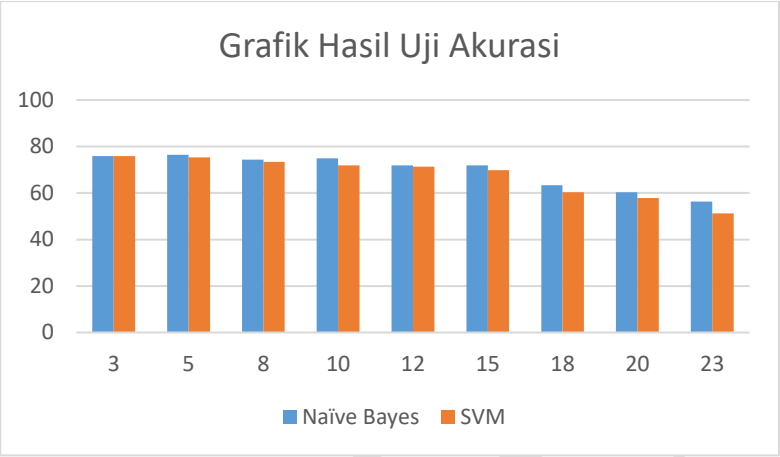

Gambar 5.4 Grafik Hasil Uji Akurasi

Tabel 5.5 Hasil Uji Retrieval

Min Support	***Naïve Bayes***	***SVM***
3	94,47%	93,96%
5	94,97%	92,46%
8	95,47%	93,46%
10	95,47%	93.96%
12	95,47%	95,47%
15	93,46%	92,96%
18	92,46%	89,94%
20	90,45%	88,94%
23	88,44%	87,93%

Berdasarkan hasil uji *retrieval* pada Tabel 5.5 dan Gambar 5.5 skor tertinggi adalah 190 yang dimiliki *Naïve Bayes* saat

minimum support bernilai 8, 10, dan 12. Skor 190 juga dicatatkan oleh SVM pada saat *minimum support* bernilai 12. Selisih rata rata *retrieval* antar *minimum support* pada *Naïve Bayes* bernilai 2 sedangkan pada *SVM* bernilai 3. Sedangkan saat *minimum support* bernilai 3 hingga 15 *Naïve Bayes* memiliki skor rata rata selisih 1.2 sedangkan *SVM* 2.8. Pada *Naïve Bayes* penurunan skor tertinggi terjadi ketika saat *minimum support* ke 12 menuju 15, 18 menuju 20 dan 20 menuju 23. Sedangkan pada *SVM* penurunan skor tertinggi terjadi saat *minimum support* ke 15 menuju 18.

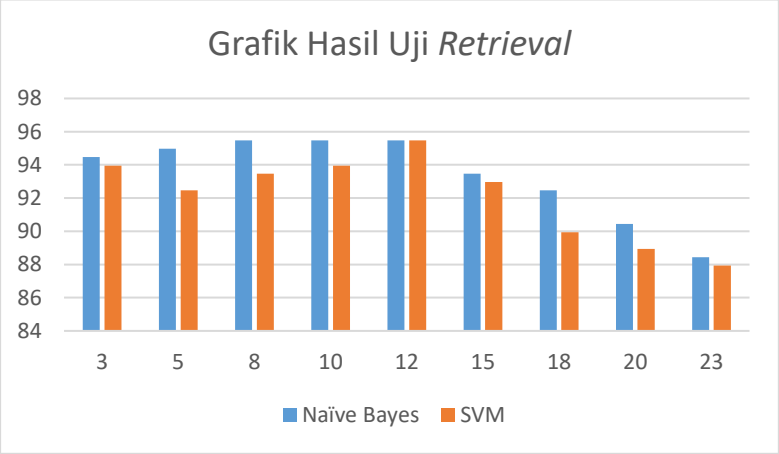

Gambar 5.5 Grafik Hasil Uji *Retrieval*

Berdasarkan hasil uji peringkat nilai pada Gambar 5.6 dan Tabel 5.6 nilai tertinggi adalah 88,04 yang dimiliki *Naïve Bayes* saat *minimum support* bernilai 10. *SVM* memiliki nilai tertinggi sebesar 85.829. Selisih rata rata nilai peringkat antar *minimum support* pada *Naïve Bayes* bernilai 1.53 sedangkan pada *SVM* bernilai 2.6. Sedangkan saat *minimum support* bernilai 3 hingga 15 *Naïve Bayes* memiliki skor rata rata selisih 0.46 sedangkan *SVM* 1.95. Pada *Naïve Bayes* penurunan skor tertinggi terjadi ketika saat *minimum support* ke 15 menuju 18. SVM

mengalami penurunan skor tertinggi terjadi juga saat minimum support ke 15 menuju 18.

Tabel 5.6 Hasil Uji Peringkat

Min Support	*Naïve Bayes*	*SVM*
3	87,135	85,829
5	87,738	85,829
8	87,738	86,030
10	88,040	85,326
12	87,738	85,628
15	86,633	82,512
18	82,512	78,894
20	80,201	76,884
23	76,683	73,969

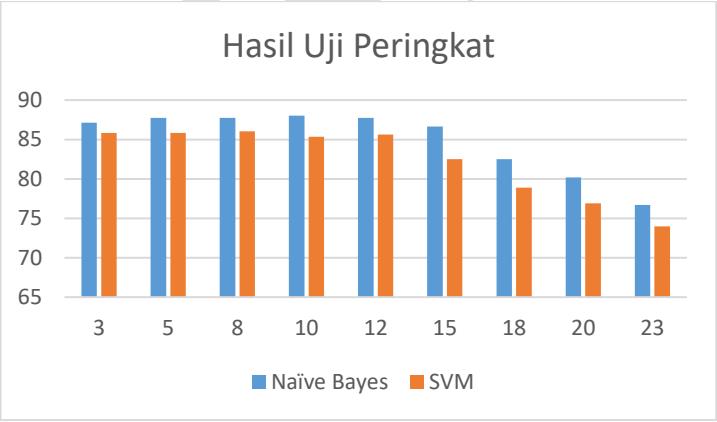

Gambar 5.6 Grafik Hasil Uji Peringkat

5.4.2 Hasil Uji Pengguna

Uji pengguna dilakukan oleh 10 orang dengan usia 20 – 25 tahun. Dengan hasil yang dapat dilihat pada Tabel 5.7.

Tabel 5.7 Hasil Uji Pengguna Dengan Pertanyaan Maksimal 30

Pengguna	Pertanyaan ke
1	20
2	22
3	18
4	15
5	18
6	23
7	22
8	23
9	20
10	17

Tabel 5.8 Hasil Uji Pengguna Dengan Pertanyaan Maksimal 20

Pengguna	Pertanyaan ke
1	20
2	20
3	20
4	20
5	20
6	20
7	20
8	20
9	18
10	18

Berdasarkan hasil pada Tabel 5.7 karena tidak ada pengguna yang menggunakan aplikasi hingga selesai maka uji

coba dilaksanakan ulang terhadap pengguna yang sama dengan jumlah pertanyaan sebanyak 20 dengan hasil yang dapat dilihat pada Tabel 5.8.

Dapat dilihat pada Tabel 5.8, 80% pengguna menyelesaikan aplikasi hingga memunculkan diagnosis. Kebanyakan pengguna berkomentar jika ada gejala yang tidak berhubungan, dan merasa bosan jika gejala tidak berhubungan. Tetapi jika gejala saling terkait dan mereka menjawab Ya maka keinginan mereka untuk menjawab pertanyaan berikutnya menjadi lebih tinggi.

5.4.3 Hasil Uji Dokter

Uji pengguna dilakukan oleh dokter yang langsung mencoba aplikasi. Dari 10 percobaan yang dilakukan oleh dokter. Dokter menilai bahwa aplikasi cukup baik walau diagnosis yang diberikan terkadang sedikit meleset. Dari segi pertanyaan dokter menilai sudah relevan dan saling terkait. Berikut merupakan salah satu hasil uji coba yang dilakukan dokter:

Informasi pasien :
Nama pasien : Kevin
Jenis kelamin : Laki - laki
Usia : 22 Tahun

Hasil anamnesis dengan format deskripsi gejala (jawaban) :

- Sakit perut (Ya)
- Muntah (Ya)
- Mual (Ya)
- Demam (Tidak)
- Diare (Tidak)
- Nafsu makan berkurang (Tidak)
- Malaise (Tidak)
- Kepala sakit (Ya)
- Demam tinggi (Tidak)
- Otot nyeri (Tidak)

- Buang air besar berdarah (Tidak)
- Perut kram (Ya)
- Kulit bintik bintik merah (Tidak)
- Perdarah gusi (Tidak)
- Kulit ruam (Tidak)
- Batuk (Ya)
- Batuk kering (Tidak)
- Batuk berdahak (Tidak)
- Tenggorokan Sakit (Ya)
- Hidung mengeluarkan ingus (Ya)
- Bersin (Ya)

Hasil diagnosis :

- faringitis· 92.24%
- influenza· 3.00%
- rhinitis· 2.14%
- leptospirosis· 0.83%
- ankilostomiasis· 0.41%

5.5 Analisis Hasil Uji Coba

Berdasarkan hasil uji coba pada sistem, *Naïve Bayes* memberikan hasil yang lebih baik daripada *SVM*. Peningkatan *minimum support* secara umum menyebabkan akurasi *classifier* turun. Hal ini dikarenakan gejala yang semakin sedikit menyebabkan kurangnya variasi fitur dari data.

Selain itu data dengan akurasi yang tertinggi tidak menyebabkan skor *retrieval* maupun peringkat juga menjadi tertinggi. Hal ini mungkin disebabkan karena sistem peringkat, karena tidak munculnya diagnosis pada 5 diagnosis tertinggi menyebabkan skor peringkat bernilai 0. Walaupun selisih nya sedikit, data dengan *classifier* Naïve Bayes dan *minimum support* sebesar 3 memberikan performa yang terbaik.

Jika diperhatikan hasil *retrieval* pada uji coba ini, artinya ada diagnosis yang tidak muncul pada uji coba data uji. Dari

analisis *dataset* dapat diperkirakan penyebabnya adalah banyaknya diagnosis yang memiliki gejala sama dengan diagnosis lainnya, terutama pada diagnosis mata, kardiovaskular, dan pernapasan.

Pada hasil uji coba pengguna dapat dilihat bahwa terlalu banyak pertanyaan menyebabkan pengguna jenuh. Walaupun secara teori akan memberikan hasil retrieval yang lebih baik karena fitur semakin banyak dan spesifik, tetapi jika pengguna enggan menyelesaikan maka tujuan dari aplikasi ini juga tidak dipenuhi.

Pengguna mengeluhkan adanya ketidaksesuaian pertanyaan gejala dengan pertanyaan sebelumnya dapat disebabkan oleh beberapa hal berikut:

- Aplikasi memberikan gejala yang meluas untuk sebelum memberika gejala yang spesifik. Sedangkan kebanyakan pengguna langsung menginginkan pertanyaan yang spesifik berdasarkan pengetahuan dia mengenai penyakit tersebut.
- Banyak data pada sumber data yang memberikan daftar gejala berbeda dengan yang pernah dialami pengguna. Sehingga pengguna merasa gejala tersebut tidak relevan.
- Pengguna merasa pertanyaan diulang, karena ada banyak gejala mirip tapi tak sama. Seperti perut nyeri dengan mual, sakit kepala dan pusing.

Pada uji dokter, dari penilaian dokter sudah memberikan respon positif baik dari segi hasil diagnosis maupun relevansi antar pertanyaan. Walau ada beberapa diagnosis yang salah, umumnya diagnosis yang salah tersebut menempati peringkat 4 dan 5. Sehingga tidak terlalu mengganggu hasil diagnosis.

BAB VI
KESIMPULAN DAN SARAN

Pada bab ini akan diberikan hasil kesimpulan yang diperoleh dari tugas akhir yang telah dikerjakan dan saran tentang pengembangan dari tugas akhir ini yang dapat dilakukan di masa yang akan datang.

6.1 Kesimpulan

Kesimpulan yang diperoleh berdasarkan hasil uji coba dan evaluasi tugas akhir ini adalah :

1. *FP Tree* memiliki hasil yang cukup baik dalam memetakan gejala gejala yang berkaitan sehingga dapat membuat tanya jawab yang saling terkait.
2. *Naïve Bayes* dan *SVM* dapat mendiagnosis penyakit berdasarkan input gejala pasien dengan baik.
3. Berdasarkan hasil pengujian *Naïve Bayes* dan SVM memberikan hasil yang hampir sama. Tetapi *Naïve Bayes* memberikan hasil yang lebih tinggi daripada SVM pada saat *minimum support* bernilai 5 dengan hasil akurasi sebesar 76,381%, hasil uji peringkat sebesar 87,738%, dan hasil uji *retrieval* sebesar 95,47%.
4. Filter *minimum support* pada data gejala memberikan hasil yang cukup signifikan pada hasil diagnosis yang diberikan. Dengan selisih rata rata antar akurasi sebesar 2,69% untuk *Naïve Bayes* dan 3,08% untuk *SVM*.

6.2 Saran

Saran yang diberikan untuk pengembangan aplikasi ini kedepannya adalah :

1. Memperbanyak variasi data kasus dan diagnosis, agar gejala yang ditanyakan lebih bervariatif dan hasil diagnosis yang lebih tepat. Data kasus juga didasarkan pada data

lapangan yang mungkin di masa depan bisa didapatkan melalui lembaga pemerintah atau rumah sakit. Perkiraan agar data menjadi lebih baik adalah sekitar 100 kasus untuk setiap diagnosis.

2. Jika saran pertama terpenuhi, disarankan melakukan percobaan diagnosis menggunakan *classifier neural network*, karena *classifier* tersebut secara teori memiliki performa yang baik terhadap *dataset* yang berukuran besar.

DAFTAR PUSTAKA

[1] A. Kirk, "The Telegraph," Telegraph Media Group, 24 Juli 2015. [Online]. Available: https://www.telegraph.co.uk/news/health/news/11760658/One-in-four-self-diagnose-on-the-internet-instead-of-visiting-the-doctor.html. [Accessed 2018 Mei 27].

[2] ecisapare, "Quizlet," 2014. [Online]. Available: https://quizlet.com/34170376/medical-terminology-medical-terms-for-disease-diagnosis-treatment-flash-cards/. [Accessed 1 January 2018].

[3] Unknown, "Medical Bits," 5 Januari 2014. [Online]. Available: https://medicalbits.wordpress.com/2014/01/05/the-anamnesis-taking-a-medical-history/. [Accessed 8 Januari 2018].

[4] A. Maae, "Quora," Quora, 25 April 2017. [Online]. Available: https://www.quora.com/What-is-support-and-confidence-in-data-mining/answer/Azim-Maae?srid=3QjiQ. [Accessed 1 Januari 2018].

[5] Unknown, "WikiBooks," 6 Agustus 2017. [Online]. Available: https://en.wikibooks.org/wiki/Data_Mining_Algorithms_In_R/Frequent_Pattern_Mining/The_FP-Growth_Algorithm. [Accessed 8 Januari 2018].

[6] F. Verhein, "wimleers.com," 10 Januari 2008. [Online]. Available: https://wimleers.com/sites/wimleers.com/files/FP-Growth%20presentation%20handouts%20%E2%80%94%C2%A0Florian%20Verhein.pdf. [Accessed 30 Juni 2018].

[7] N. Sadawi, "Generating Association Rules from Frequent Itemsets," 28 Agustus 2014. [Online]. Available: https://www.youtube.com/watch?v=-5Uia2a5jxc. [Accessed 30 Juni 2018].

[8] M. S. S. S. Tina R. Patil, "Performance Analysis of Naive Bayes and J48," *International Journal Of Computer Science And Applications*, vol. 6, p. 2, 2013.

[9] B. Stecanella, "MonkeyLearn," MonkeyLearn Inc., 25 Mei 2017. [Online]. Available: https://monkeylearn.com/blog/practical-explanation-naive-bayes-classifier/. [Accessed 30 Mei 2018].

[10] Geeks for Geeks, "Geeks for Geeks," Geeks for Geeks, [Online]. Available: https://www.geeksforgeeks.org/naive-bayes-classifiers/. [Accessed 30 June 2018].

[11] R. Saxena, "Dataaspirant," Dataaspirant, 6 Februari 2017. [Online]. Available: http://dataaspirant.com/2017/02/06/naive-bayes-classifier-machine-learning/. [Accessed 2018 Juni 30].

[12] S. Patel, "Medium," Medium Inc, 3 Mei 2017. [Online]. Available: https://medium.com/machine-learning-101/chapter-2-svm-support-vector-machine-theory-f0812effc72. [Accessed 30 Mei 2018].

[13] DF Team, "Data Flair," Data Flair, 12 Agustus 2017. [Online]. Available: https://data-flair.training/blogs/svm-kernel-functions/. [Accessed 2018 Juni 30].

[14] N. Twomey, "Quora," Quora, 7 April 2015. [Online]. Available: https://www.quora.com/Why-am-I-obtaining-better-results-with-a-linear-kernel-for-a-test-classification-task-with-SVM. [Accessed 2018 Juni 30].

[15] S. Singh, "Sadanand Notes," Github, 8 Juli 2017. [Online]. Available: https://sadanand-

singh.github.io/posts/svmpython/. [Accessed 30 Juni 2018].

[16] Unknown, "ScikitLearn - Wikipedia," Wikipedia, 16 April 2018. [Online]. Available: https://en.wikipedia.org/wiki/Scikit-learn. [Accessed 30 Mei 2018].

[17] A. Ronacher, "Flask," - - 2010-2018. [Online]. Available: http://flask.pocoo.org/. [Accessed 30 Mei 2018].

[18] A. Ronacher, "Flask," Flask, 2013. [Online]. Available: https://web.archive.org/web/20171117015927/http://flask.pocoo.org:80/docs/0.10/foreword. [Accessed 30 Mei 2018].

[19] Laravel, "Github," Github Inc, 19 Mei 2018. [Online]. Available: https://github.com/laravel/framework. [Accessed 30 Mei 2018].

[20] J. P. a. Y. Y. Jiawei Han, "Mining Frequent Patterns without Candidate Generation".

[21] B. Stecanella, "MonkeyLearn," MonkeyLearn Inc, 22 Juni 2017. [Online]. Available: https://monkeylearn.com/blog/introduction-to-support-vector-machines-svm/. [Accessed 30 Mei 2018].

[Halaman ini sengaja dikosongkan]

LAMPIRAN

1. Hasil Lengkap Uji Sistem

TRUE	Prediksi	
rhinitis	rhinitis	✓
rhinitis	rhinitis	✓
rhinitis	rhinitis	✓
influenza	influenza	✓
influenza	influenza	✓
influenza	influenza	✓
faringitis	influenza	
faringitis	influenza	
faringitis	leptospirosis	
tonsilitis	tonsilitis	✓
tonsilitis	tonsilitis	✓
tonsilitis	tonsilitis	✓
laringitis	laringitis	✓
laringitis	laringitis	✓
laringitis	laringitis	✓
pneumonia	tuberkulosis	
pneumonia	pneumonia	✓
pneumonia	pneumonia	✓
bronkopneumonia	bronkopneumonia	✓
bronkopneumonia	pneumotoraks	
bronkopneumonia	pneumonia	

TRUE	Prediksi	
pneumotoraks	pneumotoraks	✓
pneumotoraks	pneumotoraks	✓
pneumotoraks	pneumotoraks	✓
ppok-penyakit-paru-obstruktif-kronis	ppok-penyakit-paru-obstruktif-kronis	✓
ppok-penyakit-paru-obstruktif-kronis	ppok-penyakit-paru-obstruktif-kronis	✓
ppok-penyakit-paru-obstruktif-kronis	pneumotoraks	
epistaksis	epistaksis	✓
epistaksis	epistaksis	✓
epistaksis	epistaksis	✓
sinusitis	sinusitis	✓
sinusitis	sinusitis	✓
sinusitis	sinusitis	✓
tuberkulosis	tuberkulosis	✓
tuberkulosis	tuberkulosis	✓
tuberkulosis	tuberkulosis	✓
morbili	morbili	✓
morbili	morbili	✓
morbili	morbili	✓
varisela	varisela	✓
varisela	varisela	✓
varisela	varisela	✓
malaria	malaria	✓
malaria	malaria	✓
malaria	malaria	✓

TRUE	Prediksi	
leptospirosis	leptospirosis	✓
leptospirosis	leptospirosis	✓
leptospirosis	leptospirosis	✓
filariasis	filariasis	✓
filariasis	filariasis	✓
filariasis	filariasis	✓
lepra	perdarahan-subkonjungtiva	
lepra	lepra	✓
lepra	lepra	✓
lepra	lepra	✓
keracunan-makanan	keracunan-makanan	✓
keracunan-makanan	keracunan-makanan	✓
keracunan-makanan	kolesistitis	
alergi-makanan	alergi-makanan	✓
alergi-makanan	ankilostomiasis	
alergi-makanan	perdarahan-subkonjungtiva	
demam-berdarah-dengue	leptospirosis	
demam-berdarah-dengue	demam-berdarah-dengue	✓
demam-berdarah-dengue	kolesistitis	
anemia	anemia	✓
anemia	anemia	✓
anemia	anemia	✓
hiv-aids	hiv-aids	✓
hiv-aids	lupus-eritematosus-sistemik	

TRUE	Prediksi	
hiv-aids	keracunan-makanan	
lupus-eritematosus-sistemik	lupus-eritematosus-sistemik	✓
lupus-eritematosus-sistemik	lupus-eritematosus-sistemik	✓
lupus-eritematosus-sistemik	lupus-eritematosus-sistemik	✓
limfadenitis	limfadenitis	✓
limfadenitis	peritonitis	
limfadenitis	limfadenitis	✓
asam-lambung	asam-lambung	✓
asam-lambung	asam-lambung	✓
asam-lambung	asam-lambung	✓
hipertensi	pneumotoraks	
hipertensi	hipertensi	✓
hipertensi	takikardia	
cardiorespiratory-arrest	cardiorespiratory-arrest	✓
cardiorespiratory-arrest	cardiorespiratory-arrest	✓
cardiorespiratory-arrest	cardiorespiratory-arrest	✓
gagal-jantung	gagal-jantung	✓
gagal-jantung	gagal-jantung	✓
gagal-jantung	ppok-penyakit-paru-obstruktif-kronis	
takikardia	takikardia	✓
gastritis	kolesistitis	
gastritis	gastritis	✓
takikardia	infark-miokard	

TRUE	Prediksi	
gastritis	gastritis	✓
takikardia	takikardia	✓
infark-miokard	infark-miokard	✓
gastroenteritis	malaria	
gastroenteritis	keracunan-makanan	
gastroenteritis	keracunan-makanan	
disentri	disentri	✓
disentri	disentri	✓
disentri	disentri	✓
hemoroid	hemoroid	✓
infark-miokard	infark-miokard	✓
hemoroid	hemoroid	✓
hemoroid	hemoroid	✓
infark-miokard	angina-pektoris-stabil	
angina-pektoris-stabil	infark-miokard	
hepatitis-a	hepatitis-b	
hepatitis-a	hepatitis-a	✓
hepatitis-a	hepatitis-b	
angina-pektoris-stabil	angina-pektoris-stabil	✓
angina-pektoris-stabil	angina-pektoris-stabil	✓
hepatitis-b	hepatitis-b	✓
hepatitis-b	hepatitis-a	
hepatitis-b	hepatitis-b	✓
kolesistitis	kolesistitis	✓
kolesistitis	kolesistitis	✓
kolesistitis	kolesistitis	✓

TRUE	Prediksi	
apendisitis	peritonitis	
apendisitis	peritonitis	
apendisitis	peritonitis	
peritonitis	peritonitis	✓
peritonitis	peritonitis	✓
peritonitis	peritonitis	✓
serumen-prop	serumen-prop	✓
serumen-prop	serumen-prop	✓
serumen-prop	serumen-prop	✓
benda-asing-di-telinga	benda-asing-di-telinga	✓
benda-asing-di-telinga	benda-asing-di-telinga	✓
benda-asing-di-telinga	benda-asing-di-telinga	✓
askariasis	askariasis	✓
askariasis	askariasis	✓
askariasis	askariasis	✓
ankilostomiasis	ankilostomiasis	✓
ankilostomiasis	ankilostomiasis	✓
ankilostomiasis	ankilostomiasis	✓
skistosomiasis	skistosomiasis	✓
skistosomiasis	skistosomiasis	✓
skistosomiasis	skistosomiasis	✓
taeniasis	taeniasis	✓
taeniasis	taeniasis	✓
taeniasis	taeniasis	✓
strongiloidiasis	strongiloidiasis	✓
strongiloidiasis	strongiloidiasis	✓

TRUE	Prediksi	
strongiloidiasis	strongiloidiasis	✓
mata-kering	trikiasis	
mata-kering	perdarahan-subkonjungtiva	
mata-kering	konjungtivitis	
buta-senja	buta-senja	✓
buta-senja	buta-senja	✓
buta-senja	buta-senja	✓
hordeolum-bintitan	hordeolum-bintitan	✓
hordeolum-bintitan	hordeolum-bintitan	✓
hordeolum-bintitan	hordeolum-bintitan	✓
konjungtivitis	konjungtivitis	✓
konjungtivitis	hordeolum-bintitan	
konjungtivitis	konjungtivitis	✓
blefaritis	konjungtivitis	
blefaritis	blefaritis	✓
blefaritis	blefaritis	✓
perdarahan-subkonjungtiva	trikiasis	
perdarahan-subkonjungtiva	perdarahan-subkonjungtiva	✓
perdarahan-subkonjungtiva	perdarahan-subkonjungtiva	✓
astigmatisme	astigmatisme	✓
astigmatisme	astigmatisme	✓
astigmatisme	astigmatisme	✓
hipermetropia	astigmatisme	

TRUE	Prediksi	
hipermetropia	hipermetropia	✓
hipermetropia	hipermetropia	✓
miopia-ringan	miopia-ringan	✓
miopia-ringan	miopia-ringan	✓
miopia-ringan	miopia-ringan	✓
presbiopia	astigmatisme	
presbiopia	astigmatisme	
presbiopia	presbiopia	✓
katarak	presbiopia	
katarak	retinopati-diabetik	
katarak	katarak	✓
glaukoma	glaukoma	✓
glaukoma	glaukoma	✓
glaukoma	glaukoma	✓
trikiasis	trikiasis	✓
trikiasis	blefaritis	
trikiasis	episkleritis	
episkleritis	episkleritis	✓
episkleritis	episkleritis	✓
episkleritis	episkleritis	✓
hifema	hifema	✓
hifema	hifema	✓
hifema	hifema	✓
retinopati-diabetik	retinopati-diabetik	✓
retinopati-diabetik	retinopati-diabetik	✓
retinopati-diabetik	hifema	

TRUE	Prediksi	
otitis-eksterna	otitis-eksterna	✓
otitis-eksterna	otitis-eksterna	✓
otitis-eksterna	otitis-eksterna	✓
otitis-media	otitis-media	✓
otitis-media	otitis-media	✓
otitis-media	otitis-eksterna	

2. Hasil Lengkap Uji Dokter

A. Uji Coba 1

Informasi Pasien
Jenis Kelamin : Laki - laki
Usia : 22 Tahun

Gejala	**Jawaban**
Sakit perut	Ya (jawaban awal)
Muntah	Ya
Mual	Ya
Demam	Tidak
Diare	Tidak
Nafsu makan berkurang	Tidak
Malaise	Tidak
Kepala sakit	Ya
Demam tinggi	Tidak
Otot nyeri	Tidak
Buang air besar berdarah	Tidak
Perut kram	Ya
Kulit bintik bintik merah	Tidak
Perdarah gusi	Tidak
Kulit ruam	Tidak

Gejala	Jawaban
Batuk	Ya
Batuk kering	Tidak
Batuk berdahak	Tidak
Tenggorokan Sakit	Ya
Hidung mengeluarkan ingus	Ya
Bersin	Ya

Hasil diagnosis :

- faringitis· 92.24%
- influenza· 3.00%
- rhinitis· 2.14%
- leptospirosis· 0.83%
- ankilostomiasis· 0.41%

B. Uji Coba 2

Informasi Pasien
Jenis Kelamin : Laki - laki
Usia : 62 Tahun

Gejala	Jawaban
Penglihatan Kabur	Ya (jawaban awal)
Kepala Sakit/Nyeri	Tidak
memincingkan mata untuk melihat lebih jelas	Ya
Penglihatan kabur jarak jauh	Ya
Mata lelah	Ya
Pusing	Tidak
Mata perih mata panas	Tidak
penglihatan kabur jarak dekat	Ya
Mata kering	Tidak
Mata gatal	Tidak

Gejala	Jawaban
Fotofobia	Tidak
kesulitan membaca	Ya
Mata merah	Tidak

Hasil diagnosis :

- miopia-ringan· 52.41%
- hipermetropia· 45.48%
- astigmatisme· 1.91%
- presbiopia· 0.21%
- retinopati-diabetik· 0.00%

C. Uji Coba 3

Informasi Pasien
Jenis Kelamin : Perempuan
Usia : 22 Tahun

Gejala	Jawaban
Sakit Perut	Ya (jawaban awal)
Muntah	Tidak
Mual	Tidak
Diare	Tidak
Demam	Tidak
Nafsu Makan Berkurang	Tidak
Malaise	Ya
Penurunan berat badan	Tidak
Ikterus	Tidak
Menggigil	Tidak
Batuk	Tidak
Kepala Sakit/Nyeri	Tidak
Buang air besar berdarah	Ya
Urine berdarah	Tidak
kulit ruam	Tidak

Gejala	Jawaban
Kulit gatal	Tidak
Perut kram	Ya
Buang air besar berulang	Ya
Demam Tinggi	Tidak
Kembung	Ya
Nyeri tekan perut	Ya

Hasil diagnosis :

- gastroenteritis· 71.45%
- disentri· 25.36%
- taeniasis· 0.67%
- peritonitis· 0.53%
- skistosomiasis· 0.51%

D. Uji Coba 4

Informasi Pasien
Jenis Kelamin : Laki laki
Usia : 34 Tahun

Gejala	Jawaban
Sesak Dada	Ya
Dada nyeri	Ya
Sesak nafas	Ya
Nadi cepat jantung cepat	Ya
takipnea	Ya
mual	Tidak
Dada terasa berat	Ya
Batuk	Tidak
Malaise	Tidak
Demam	Tidak
Batuk berdahak	Tidak
Pusing	Tidak

Gejala	Jawaban
Kepala sakit/nyeri	Tidak
Palpitasi	Ya
Kulit Ruam	Tidak
Tenggorokan Sakit Nyeri	Tidak
Merokok	Ya
Obesitas	Tidak
Mengi	Ya
Riwayat gangguan jantung	Ya
Batuk kronis	Tidak

Hasil diagnosis :

- pneumotoraks· 83.33%
- infark-miokard· 12.60%
- gagal-jantung· 2.80%
- angina-pektoris-stabil· 0.64%
- takikardia· 0.60%

E. Uji Coba 5

Informasi Pasien
Jenis Kelamin : Perempuan
Usia : 15 Tahun

Gejala	Jawaban
Hidung tersumbat	Ya
Hidung mengeluarkan ingus (pilek)	Ya
Bersin	Ya
Hidung gatal	Tidak
Kepala sakit/nyeri	Tidak
Batuk	Ya
Batuk kering	Tidak
Batuk berdahak	Ya
Demam	Ya

Gejala	Jawaban
Demam Tinggi	Tidak
Demam > 3 hari	Tidak
Tenggorokan sakit/nyeri	Ya
Malaise	Ya
Wajah nyeri	Ya
Kulit bintik bintik merah	Tidak
Ingus berwarna hijau	Tidak
Otot nyeri	Tidak
Nafas Bau	Tidak
Sesak nafas	Tidak
Nafsu makan berkurang	Ya
Mengigil	Tidak

Hasil diagnosis :

- influenza· 69.48%
- rhinitis· 20.35%
- faringitis· 4.81%
- sinusitis· 3.79%
- bronkopneumonia· 1.03%

F. Uji Coba 6

Informasi Pasien
Jenis Kelamin : Laki laki
Usia : 34 Tahun

Gejala	Jawaban
Suara serak	Ya
Tenggorokan Sakit/Nyeri	Ya
Batuk	Tidak
Demam	Tidak
Suara hilang	Ya
Batuk kering	Tidak

Gejala	Jawaban
Suara parau	Ya
Kepala sakit/nyeri	Tidak
Malaise	Tidak
Hidung mengeluarkan ingus	Tidak
Tenggorokan Sakit/Nyeri saat menelan	Ya
Otot nyeri	Tidak
Nafsu makan berkurang	Tidak
Mual	Tidak
Demam tinggi	Tidak
Sendi nyeri	Tidak
Bersin	TIdak
Diare	Tidak
Sesak nafas	Tidak
Muntah	Tidak
Kulit ruam	Tidak

Hasil diagnosis :

- laringitis· 99.35%
- asam-lambung· 0.41%
- tonsilitis· 0.16%
- perdarahan-subkonjungtiva· 0.02%
- faringitis· 0.02%

G. Uji Coba 7

Informasi Pasien
Jenis Kelamin : Laki laki
Usia : 35 Tahun

Gejala	Jawaban
Demam tinggi	Ya
Demam	Ya
Demam > 3 hari	Ya

Gejala	Jawaban
Kepala sakit/nyeri	Ya
Muntah	Tidak
Mual	TIdak
Otot Nyeri	Tidak
Tenggorokan Sakit/Nyeri	Tidak
Diare	Tidak
Malaise	Ya
Tenggorokan Sakit/Nyeri saat menelan	Tidak
Batuk	Ya
Batuk Kering	Ya
Hidung mengeluarkan ingus (pilek)	Tidak
Sesak nafas	Ya
Batuk berdahak	Ya
Nafsu makan berkurang	Ya
Mengigil	Tidak
Dada nyeri	Tidak
Napas Pendek dan terengah engah (napas cepat)	Tidak
Penurunan berat badan	Tidak

Hasil diagnosis :

- pneumonia· 59.65%
- bronkopneumonia· 35.01%
- influenza· 1.82%
- tuberkulosis· 1.60%
- ppok-penyakit-paru-obstruktif-kronis· 1.51%

H. Uji Coba 8

Informasi Pasien
Jenis Kelamin : Perempuan
Usia : 22 Tahun

Gejala	Jawaban
Pingsan mendadak	Ya
Tidak ada nafas	Ya
Pusing	Tidak
Henti Jantung	Ya
Tidak sadar	Ya
Dada nyeri	Ya
Palpitasi (Denyut Detak Jantung Tidak Beraturan)	Ya
Takipnea	Ya
Malaise	Tidak
Sesak nafas	Ya
Nadi cepat jantung cepat	Ya
Sesak dada	Ya
Mual	Tidak
Dada terasa berat	Tidak
Dada nyeri menjalar ke punggung, lengan, bahu	Ya

Hasil diagnosis :

- cardiorespiratory-arrest· 98.17%
- pneumotoraks· 1.34%
- infark-miokard· 0.28%
- takikardia· 0.13%
- angina-pektoris-stabil· 0.08%

I. Uji Coba 9

Perempuan, 57 tahun

Gejala	Jawaban
Mata merah	Ya
Mata berair	Ya
Fotofobia	Ya
Mata gatal	Ya

Gejala	Jawaban
Mata kering	Tidak
Mata perih	Tidak
Mata bengkak	Tidak
Memiliki riwayat alergi	Tidak
Kelopak mata bengkak	Tidak
Kulit gatal	Tidak
Bersin	Tidak
Mata nyeri	Ya
Bulu mata lengket	Tidak
Mata sensasi berpasir	Tidak
Mata lelah	Tidak
Hidung mengeluarkan ingus (pilek)	Tidak
Kulit ruam	Tidak
Sesak nafas	Tidak
Mata muncul kotoran di sekeliling kelopak mata (belek)	Ya
Takipnea	Tidak
Hidung tersumbat	Tidak

Hasil diagnosis :

- konjungtivitis· 86.16%
- episkleritis· 8.29%
- perdarahan-subkonjungtiva· 2.19%
- trikiasis· 2.01%
- hordeolum-bintitan· 0.85%

J. Uji Coba 10

Informasi Pasien
Jenis Kelamin : Laki laki
Usia : 67 Tahun

Gejala	Jawaban
Kulit ruam	Ya
Demam	Ya
Demam tinggi	Tidak
Demam > 3 hari	Tidak
Malaise	Tidak
Diare	Tidak
Otot nyeri	Tidak
Kepala sakit/nyeri	Tidak
Batuk	Tidak
Tenggorokan sakit	Tidak
Penurunan berat badan	Tidak
Sendi nyeri	Tidak
Kulit bintik merah	Ya
Hidung mengeluarkan ingus	Tidak
Kulit memerah	Ya
Mual	Tidak
Muntah	Tidak
nafsu makan berkurang	Tidak
Sakit perut	Tidak
Mengigil	Tidak
Sesak nafas	Tidak

Hasil diagnosis :

- morbili· 69.75%
- lupus-eritematosus-sistemik· 27.99%
- filariasis· 1.01%
- lepra· 0.39%
- ankilostomiasis· 0.22%

[Halaman ini sengaja dikosongkan]

BIODATA PENULIS

Kevin Alif Fachreza lahir di Magetan pada 9 Maret 1997 menghabiskan masa kecil di Tangerang Selatan dan masa remaja di Surabaya. Penulis menempuh pendidikan sekolah dasar di SD Tirta Buaran Tangerang (2002 – 2007) dan SD Dewi Sartika Surabaya (2007 - 2008), lalu di SMPN 1 Surabaya (2008 – 2011) terakhir di SMAN 9 Surabaya (2011 – 2014). Setelah menempuh pendidikan SMA penulis melanjutkan kuliah di Teknik Informatika ITS pada 2014 – 2018. Selama menempuh kuliah penulis aktif pada organisasi himpunan jurusan.

Pada 2017 penulis membuat aplikasi Medify yang digunakan oleh banyak dokter dan pada tahun yang sama penulis mendirikan perusahaan PT Global Medika Digitama, dan memiliki jabatan sebagai *Chief Executive Officer*. Penulis dapat dihubungi melalui *email* kevin@medify.id